화면과 검증을 늘렸고, 제품 연결은 다음 주에 확인한다

triPilot

5주차 진행경과

2026-09-29 ~ 2026-10-06

작업 브랜치 커밋

402건

role-manager · git log

2026-09-29 ~ 10-06

모든 브랜치 커밋

531건

팀원 커밋 포함 · git log

2026-09-29 ~ 10-06

화면 구현과 자동 시험은 늘었고, 사람 평가는 아직 없다

웹 화면 구현

12개

화면설계서 5주차 · 2026-10-06 기준
cs 프로젝트 서버 연결 · 캡처는 mock 서버

cs 프로젝트 자동 시험

99.9%

4,245 / 4,251 · 2026-10-06 18:09
실제 모델 시험 238개 제외

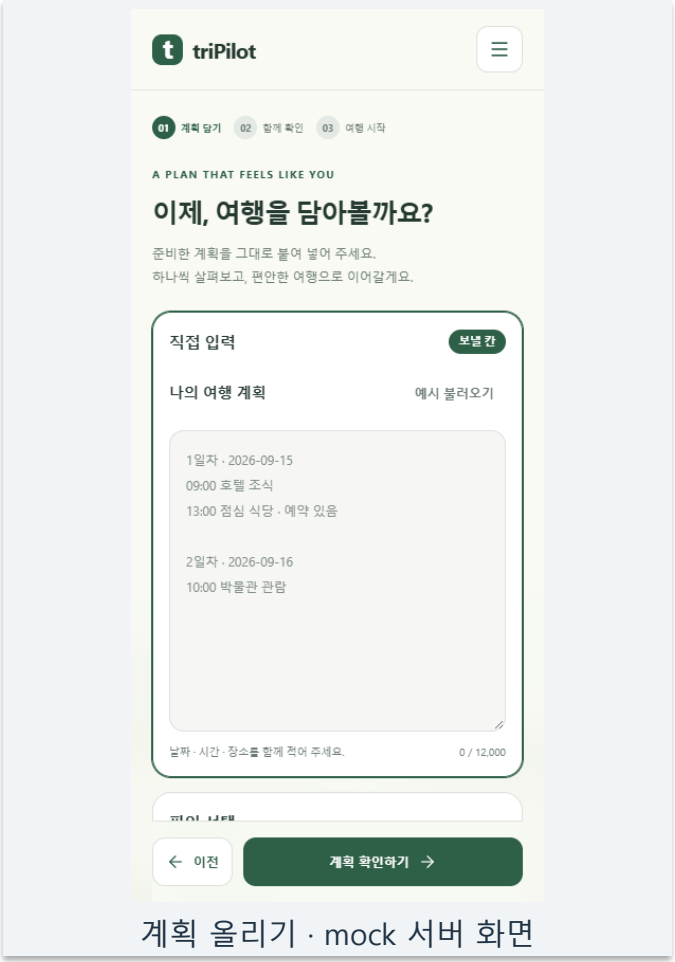
사람 평가

0건

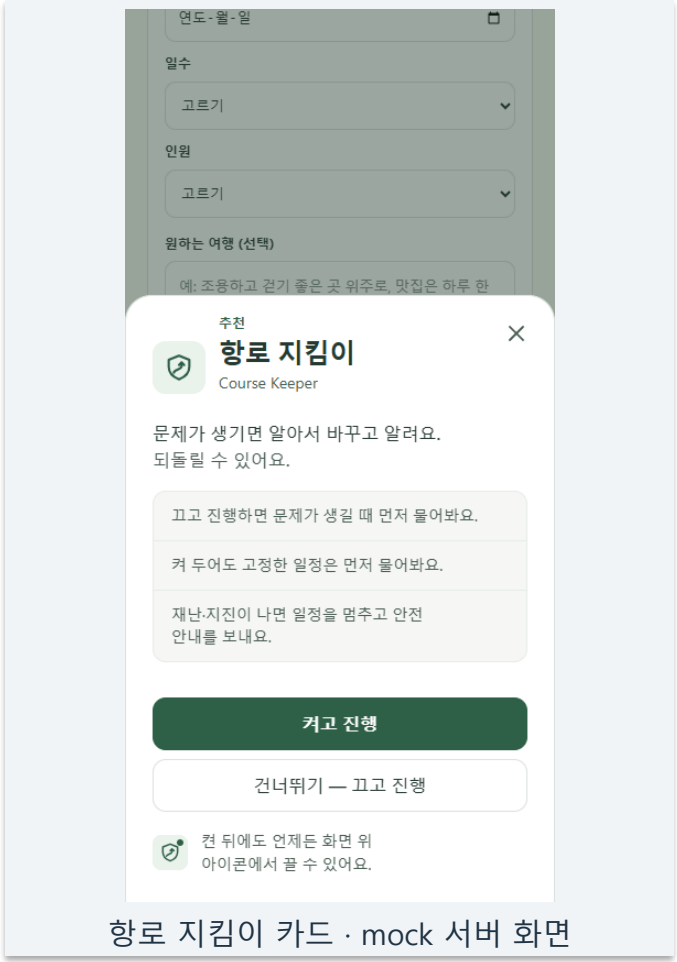
2026-10-06 기준 · 평가 시트 35행 준비
모델 시험 문제는 전부 합성

구현, 자동 시험, 사람 평가는 서로 다른 확인 범위다.

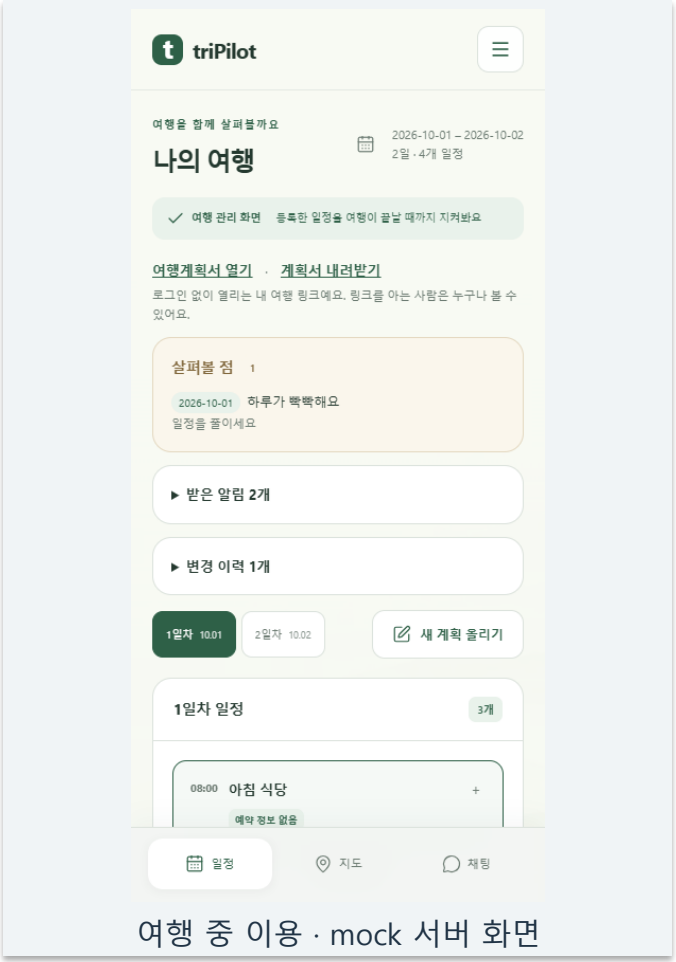
자유여행자의 계획 접수부터 여행 중 이용까지 화면을 붙였다



계획 올리기 · mock 서버 화면



항로 지킴이 카드 · mock 서버 화면



여행 중 이용 · mock 서버 화면

실제 응답 확인: 계획 확인의 읽기·결과·수정·등록만 · 2026-10-03. 이후 변경 화면은 미확인.

개인 AI 입구와 실시간 진행을 구현했고, 실제 연결 확인은 남았다

MCP 여행 도구

15 / 15

통과 / 시험 · 2026-10-02
읽기 5 · 쓰기 7 · 쓰기는 기본 꺼짐

웹 실시간 진행

21 / 21

통과 / 시험 · 2026-10-02
SSE · 채팅·일정 짜기·접수 읽기

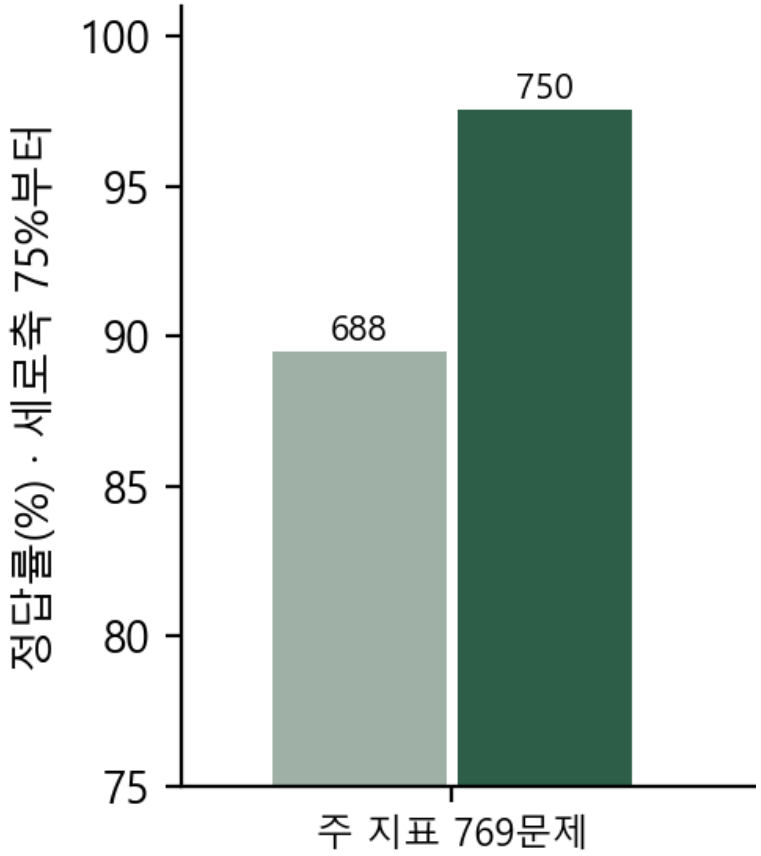
팀 재배분

10 / 10

통과 / mock 서버 시험 · 2026-10-06
받는 팀이 없으면 등록 팀에서 한 번 재선택

여행 삭제·디스코드·텔레그램: cs 프로젝트 서버 코드 구현. x600 서버 반영·실제 연결 미확인.

Gemma 4 E4B를 가르치니 같은 시험의 정답이 늘었다



원본 파인튜닝_전후.png의 주 지표 부분 발췌. 비교는 같은 769문제이며 사람 평가가 아니다.

QLoRA 학습 후

750 / 769

정답 / 합성 시험 · 97.5%

mix8~12 · 요청 둘 66문제 제외

학습 전 688 / 769

시드를 바꾼 재시험

760 / 769

정답 / 같은 합성 시험 · 98.8%

학습 전 대비 이쪽만 정답 69 : 7

p=6.4e-14 · 제품 연결 전

가르친 작은 모델이 큰 로컬 모델을 넘었지만, 모델 순위는 미정이다

같은 합성 시험에서의 정답 수



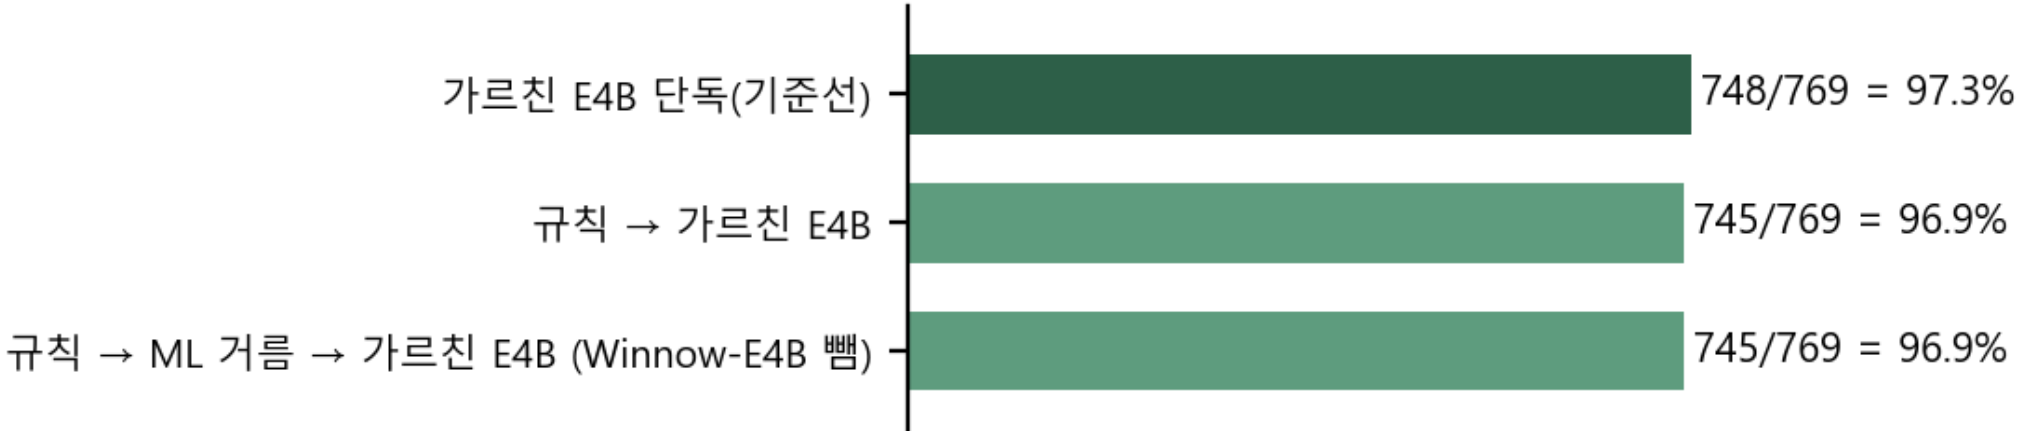
756 / 769

정답 / 같은 합성 시험 · 가르친 Winnow-E4B(Jev 계열 모델) · 시드 1개

E4B와 구분 안 됨 · 모델 사이 순위는 시드 3개 이상 필요

모델별_769_비교.png에서 확인된 로컬 비교 행만 발췌. 큰 로컬 모델은 학습 없음.

규칙과 ML은 호출을 줄였지만, 단계를 늘려도 정답은 늘지 않았다



가르친 E4B 호출

19% 감소

규칙 + ML 거름 대 E4B 단독 · 정답 745 대 748 /769
GPU 서버 C · 2026-10-06 · 구분 안 됨

학습 없는 Winnow-E4B 포함

697 / 769

Jev 계열 모델 · 학습 조건 달라 공정 비교 아님
사후 개선 판 · 사전 등록 판은 472 / 769

한줄연결_시험.png의 확인된 기준 구성만 발췌. 일정과 무관한 말이 섞인 흐름에서는 앞단이 이득.

분류는 개선됐지만, 규정 검색은 목표에 못 미쳤다

학습한 분류 인코더의 긴급도

88.4%

CX 400 · Codex 작성 · Claude 교차 라벨

학습 없는 E4B 60.9% 대 학습 후 88.4%

정답 규정이 상위 3개 안

30 / 48

62.5% · 제품 코드 그대로 · 독립 질문 B

2026-10-06 · 양식 목표 0.90 미달

고객용 색인은 정답 노출과 불필요한 노출을 함께 늘렸다

정답 노출 21/48 → 31/48

독립 질문 B · 2026-10-06 · 운영 반영 결정 전

불필요한 노출 22.3% → 36.7%

규정이 아닌 여행 대화에 규정을 붙인 비율

발표 수치는 2026-10-06 제품 코드 그대로 잰 규정 검색 결과(독립 질문 B 48문제, 합성).

5주차 산출물과 6주차 시험 문서를 만들고 지적을 반영했다

벡터DB·GraphDB 구축 결과서	23쪽
멀티 에이전트 테스트 계획 및 결과 보고서	50쪽
요구사항 정의서 업데이트	85개 요구
화면설계서	25쪽
6주차 서비스 테스트 계획 및 결과 보고서	10쪽

요구사항 구현 끝

24 / 85

2026-10-06 업데이트 기준
일부 구현 58 · 결정 대기 3
구현 상태이며 시험 통과율이 아님

산출물 분량·요구사항 상태: 주간_사실.md의 산출물 기록. 모두 교차 검증 후 지적 반영.

합성 시험의 성과와 별개로, 데이터 변조와 실제 응답 확인이 남았다

사람 평가

0건

2026-10-06 기준 · 시트 35행만 준비
합성 시험 결과의 실제 사용 검증 전

계획 읽기 값 변조

12 / 350

변조 / 시험 · 3.4%
2026-10-06 주간 사실 기준

일정 항목 짚기 빈 답

85 / 2,735

빈 답 / 흐름 시험 · 3.1%
2026-10-06 기준 · 원인 미확인

엉뚱한 대상 변경 1/172

발생 / 결정 단위 · 주간 사실 기준

금액 단위 변조 1건 통과

일본어 알림 번역 · 원을 엔으로 변경 · 주간 사실 기준

규정 검색 목표 미달도 미해결. 변경 화면 대부분 실제 응답 미확인 · 가르친 모델 제품 연결 전.

다음 주에는 실제 응답과 사람 평가를 확인하고 제품 반영을 결정한다

사람 평가 진행

35행

이미 준비한 평가 시트 행 수

6주차 예정 · 완료한 평가 수가 아님

모델 순위 재확인

시드 3개 이상

가르친 모델 제품 연결 검토와 함께 진행

6주차 예정 · 현재 순위 확정 전

바뀐 화면의 실제 응답 확인
규정 색인 개선을 분류기 뒤에서 다시 측정

Jev 계열 후보: Plumb-4B · spark-s1-4b-v6 · jevify-gemma4-e4b

같은 방법으로 가르쳐 비교 예정 · GPU 서버 B 대기열