SKN32 Final 6팀 · A-COPilot

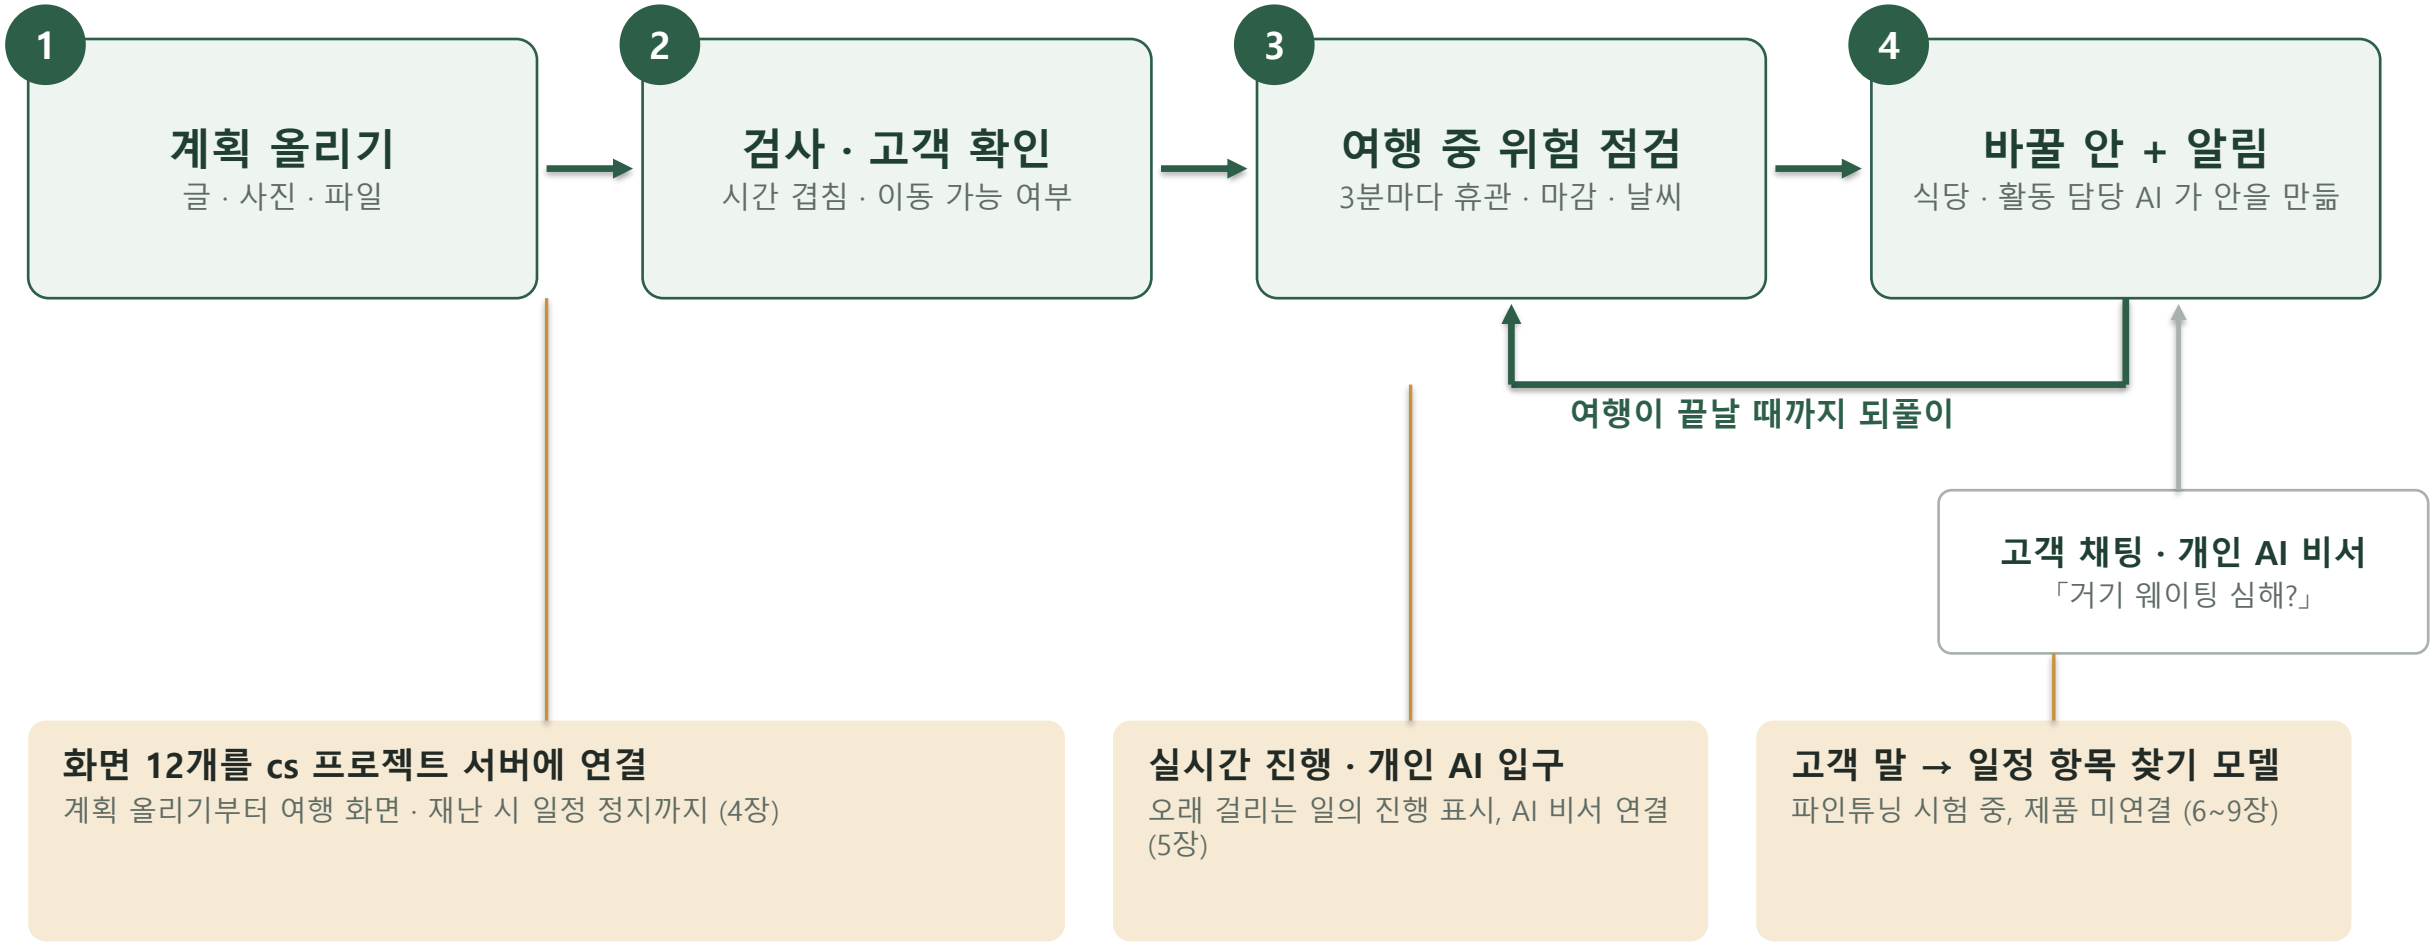
triPilot 5주차 진행 경과

자유여행자가 올린 여행 계획을 여행이 끝날 때까지 지켜 주는 서비스

2026.09.29 ~ 10.06 스탠드업

올린 계획을 여행 내내 지키는 흐름에서, 이번 주엔 세 곳을 손봤습니다

초록 칸은 서비스가 하는 일, 금색 꼬리표는 이번 주에 손댄 곳입니다

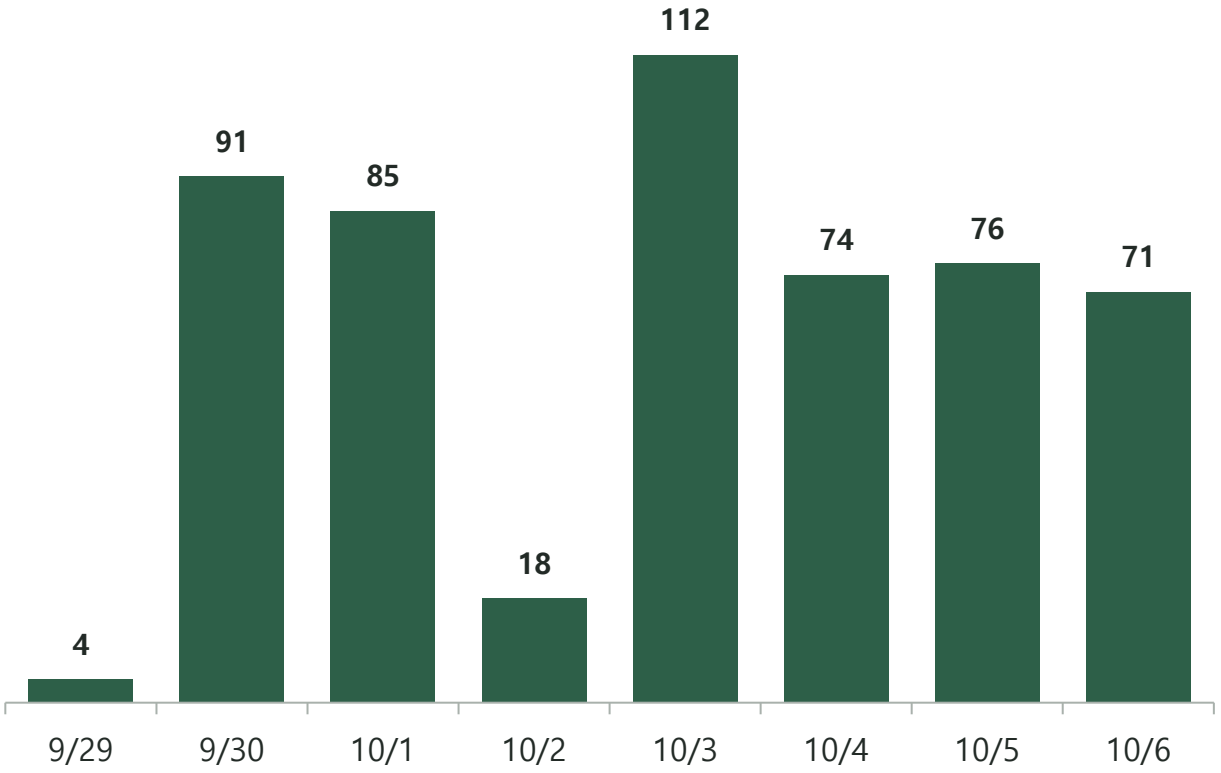


흐름은「아키텍처 한눈에 v26」그림 1(계획 확인) · 그림 4(에이전트 구성)를 줄인 것입니다. 알림은 디스코드 등으로, 바뀐 내용은 로그인 없이 열리는 여행계획서 링크에도 반영됩니다.

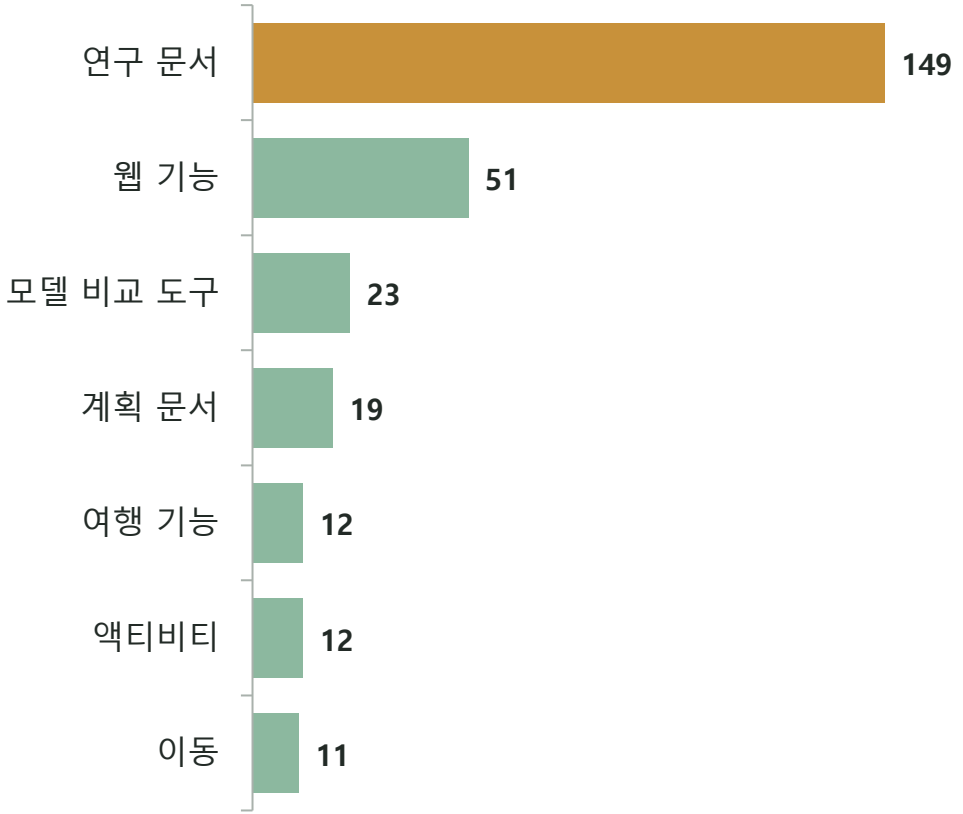
한 주 동안 커밋 531건, 연구 문서와 웹 기능이 가장 많았습니다

커밋 = 코드나 문서를 저장소에 한 번 저장한 단위. 팀원 브랜치까지 모든 브랜치를 셌습니다

날짜별 커밋 수 (모든 브랜치, 합계 531)



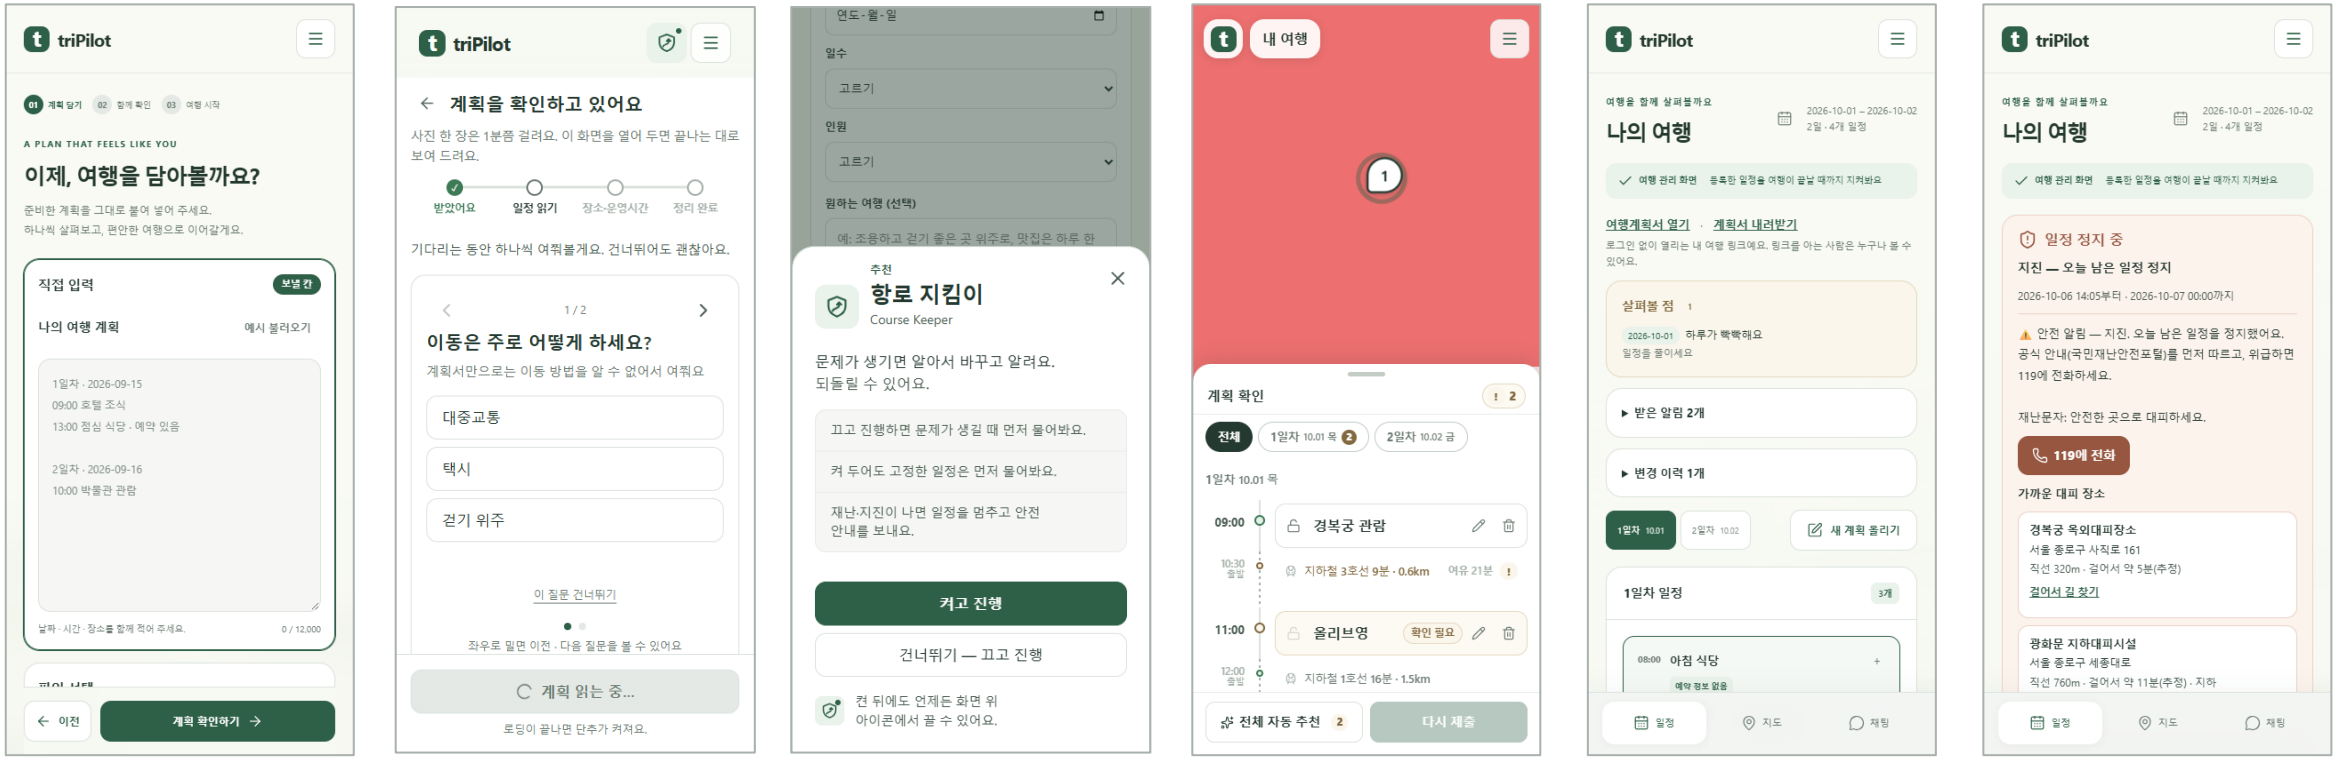
무엇을 했나 (커밋 제목 머리로 나눈 277건)



git log, 2026-09-29 ~ 10-06. 작업 브랜치(role-manager)만 세면 402건. 오른쪽은 제목에 영역 머리(docs(research) 등)가 붙은 277건만 나눴고, 나머지 254건은 머리가 없어 나누지 않았습니다.

고객이 계획을 올리고 여행이 끝날 때까지 쓰는 화면을 이어 붙였습니다

휴대폰 화면 기준, 왼쪽에서 오른쪽으로 고객이 지나가는 순서입니다

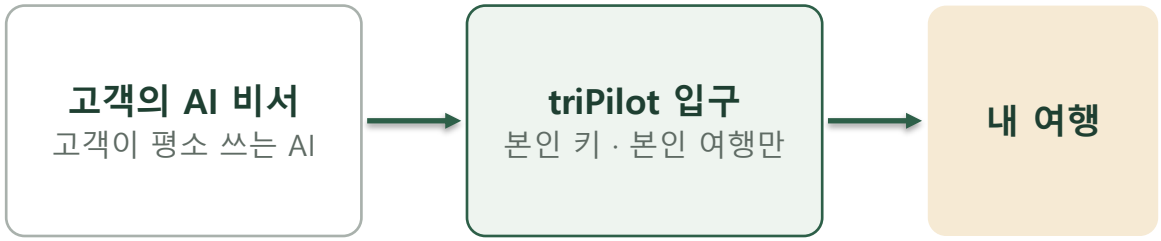


1	2	3	4	5	6
계획 올리기	**계획 읽는 중**	**항로 지킴이**	**계획 확인**	**여행 화면**	**재난 시 일정 정지**
글을 붙여 넣거나 사진 · 파일	기다리는 동안 취향 질문	문제 생기면 먼저 바꿀지 고름	날짜별 일정 · 지도 · 수정	일정 · 지도 · 채팅 · 알림	안전 안내 · 119 · 대피 장소

mock 서버(같은 모양의 답만 흉내 내는 시험용 서버)로 화면 반응을 확인. 실서버 확인은 계획 확인 화면 일부만(10-03), 바뀐 화면은 아직입니다.

고객의 AI 비서가 들어올 입구와, 기다리는 동안의 진행 표시가 생겼습니다

개인 AI 입구



읽기 일정 · 위험 점검 결과 · 이동 판정을 물어봄 **켜짐**
고치기 일정 수정 · 신고 **기본 꺼짐(설정으로 켬)**

실시간 진행 표시



계획 읽기 · 일정 짜기 · 채팅처럼 수십 초 걸리는 일을 하는 동안, 지금 몇 단계인지와 **3초마다「살아 있음」신호**를 화면에 보냅니다. 멈췄는지 기다리는 중인지 고객이 알 수 있습니다.

15/15
자동 시험 통과
2026-10-02, 본인 여행만 열리는지 · 꺼진 쓰기가 막히는지

10/10
담당 다시 고르기
맡을 담당 AI 가 없을 때 한 번 더 고름, mock 서버 시험

21/21
자동 시험 통과
2026-10-02, 채팅 · 일정 짜기 · 계획 읽기

517/517
식당 담당 AI 시험
팀원 정세환, 2026-10-06

개인 AI 입구는 MCP 서버로 만들었습니다. 디스코드 · 텔레그램 연결과 여행 삭제는 코드에 들어갔지만 x600 서버 반영과 실제 연결은 아직 확인하지 않았습니다.

모델이 푸는 문제: 고객의 말이 일정표의 몇 번 항목을 가리키는지 찾기

어느 항목인지 알아야 그 장소의 영업시간 · 예약을 확인하고 바꿀 수 있습니다

고객 일정표 (일부)

23번	금 13:30	대림미술관 전시 관람
24번	금 15:30	호텔 체크인
25번	금 16:30	**피크닉 전시 보기**

시험지 769문제

헷갈리게 만든 11가지 유형: 「거기」 같은 가리킴 말 · 비슷한 이름(대림미술관 / 대림창고) · 「~말고」 · 오타 · 일정과 무관한 잡담 · 그럴듯하지만 없는 일정 등

AI 모델(Codex · Claude)이 쓴 합성 문제. 처음 문제와 체크리스트는 사람이 썼고 일부를 사람이 검수

고객
금요일에 전시 뭐 봐?

triPilot
금요일엔 13:30 대림미술관 전시 관람, 16:30 피크닉 전시 보기가 있어요.

고객
뒤에 거 예매해야 돼?

→ **정답: 25번**
「뒤에 거」 = 피크닉 전시

고객
남산타워 몇 시에 올라가?

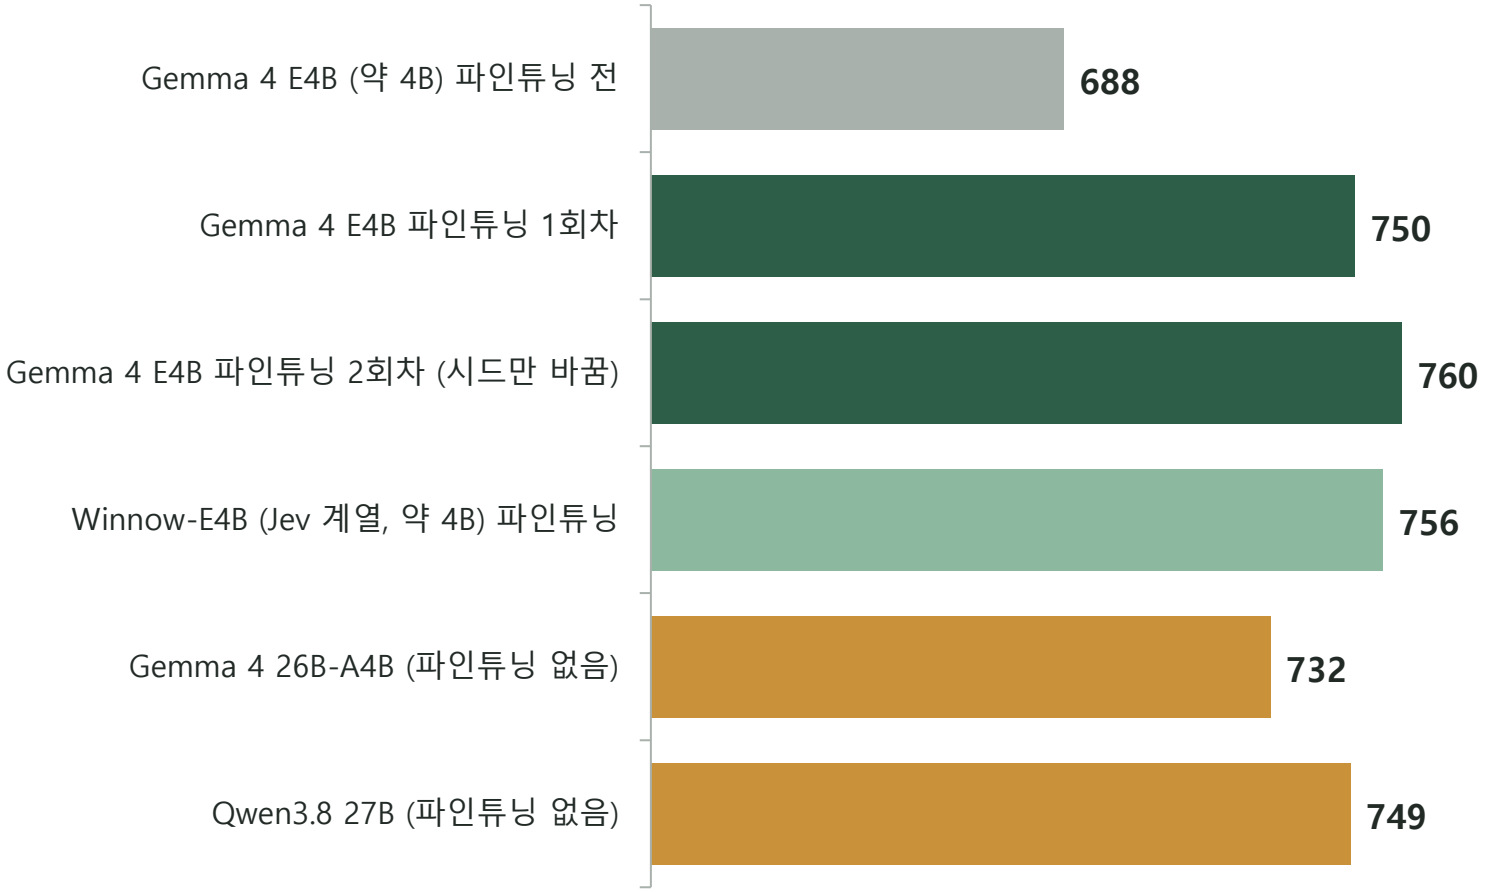
→ **정답: 없음**
일정에 없는 곳은 지어내지 않음

769 = 835 − 66 한 문장에 항목 두 개를 묻는 66문제(「점심이랑 저녁 다 알려 줘」 유형)는 채점 기준을 따로 두어 주 점수에서 뺐습니다.

예시는 시험 세트 mix12(Claude 작성)의 실제 문제입니다. 일정은 가상 여행자 일정이고 날짜는 2027-11-05(금)입니다.

약 4B 모델을 파인튜닝하니 26B · 27B 로컬 모델만큼 맞혔습니다

같은 769문제, 같은 채점. 막대 끝 숫자가 맞힌 문제 수입니다



이 장의 말

학습 자료 연습문제 1,760개. 처음 문제와 체크리스트는 사람이 쓰고, 이를 바탕으로 Claude 가 늘림(일부 사람 검수)

방법 QLoRA, 같은 설정으로 시드만 바꿔 두 번 → 750 · 760

Jev 계열 모델 선택지 중 하나를 고르는 결정 전용 공개 모델 묶음. Winnow-E4B 는 그중 하나

평균 4.55초

GPU 없이 CPU 4코어로 이어지는 질문

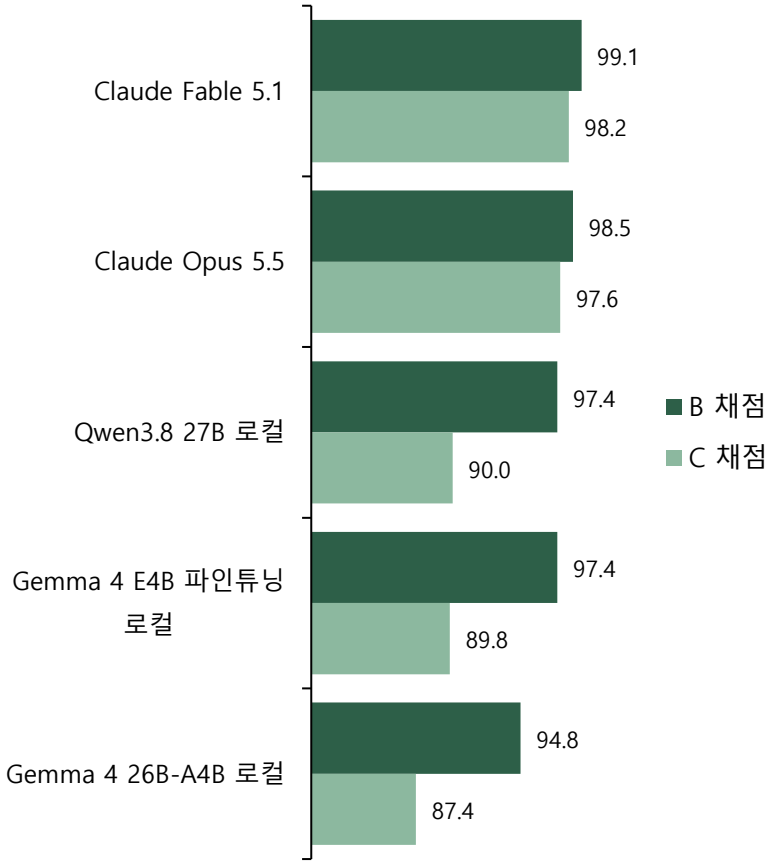
파인튜닝 E4B 를 8비트로 줄인 7.5GB 파일. 새 일정 첫 질문은 평균 67.5초

파인튜닝 전 대비 파인튜닝 1회차만 맞힌 문제 69 : 반대 7 (p=6.4e-14, 우연으로 보기 어려움). 4B 모델끼리 차이(750 · 756 · 760)는 시드 흔들림 안이라 순위를 매기지 않습니다. 상용 모델은 다음 장에서 출제자를 빼고 비교합니다.

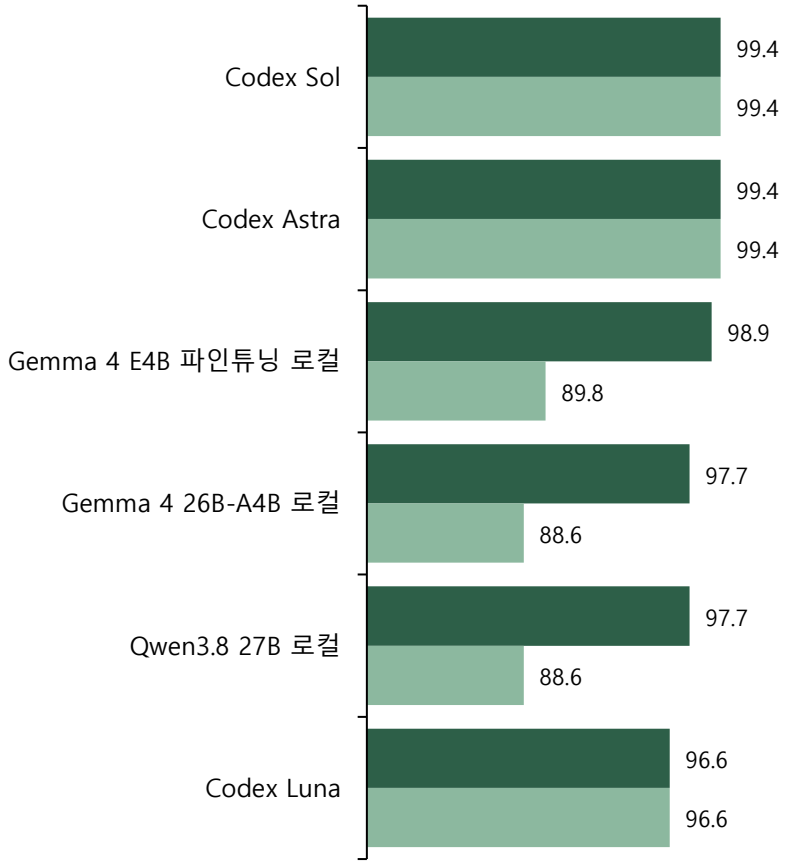
문제를 낸 AI 는 그 문제에서 빼고 다시 재도, 상용 모델이 가장 높았습니다

Codex 가 쓴 문제에서는 Codex 를, Claude 가 쓴 문제에서는 Claude 를 빼고 B · C 두 채점으로 비교했습니다

Codex 가 쓴 659문제 · Codex 제외



Claude 가 쓴 176문제 · Claude 제외



이 장의 말

왜 빼나 문제를 쓴 AI 는 자기 말투 · 정답 기준에 익숙해 점수가 부풀 수 있음

B 채점 한 문장에 항목 둘을 묻는 질문은 하나라도 맞으면 정답

C 채점 낸 항목 묶음이 정답 묶음과 완전히 같아야 정답

읽는 법

B 에서 파인튜닝 E4B 는 27B 와 같은 642/659. C 에서 로컬이 낮은 건 항목을 하나만 내는 구조라 「둘 다」 질문을 놓쳐서입니다.

저장된 문제별 풀이를 다시 셈(새 호출 없음). 남는 치우침: 「둘 다」 질문의 정답 묶음과 파인튜닝 E4B 의 학습 자료는 Claude 가 만들었습니다. mix12 는 176문제라 1~2문제 차이는 구분 안 됨.

앞단에 규칙 · 작은 분류 모델을 두니 점수는 같고 호출은 19% 줄었습니다

E2E 파이프라인 테스트: 단계를 실제로 이어 붙이고 문제마다 처음부터 끝까지 돌렸습니다 (GPU 서버 C, 2026-10-06)

문제 835개 입력

복수 항목 질의 66개 포함

↓

규칙이 125개를 바로 처리

「첫 번째」·「~말고」· 같은 장소 같은 말 패턴

↓

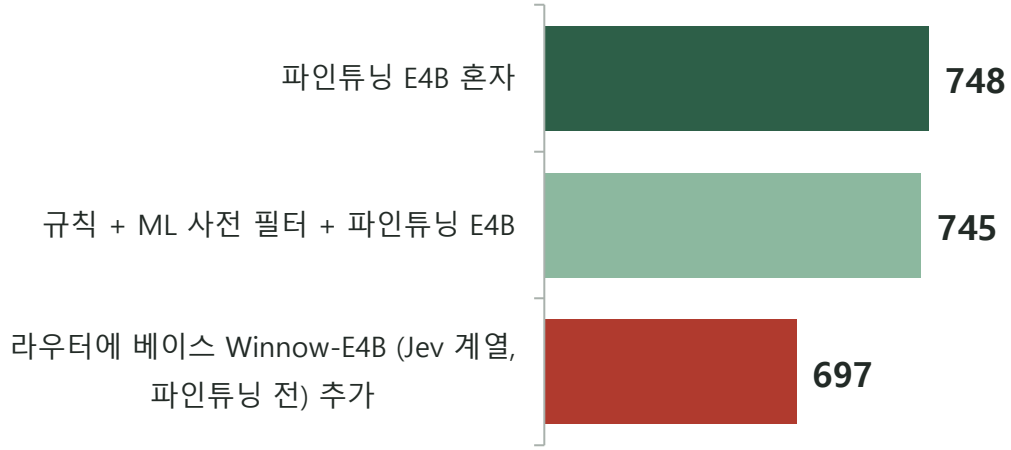
ML 사전 필터가 36개를 처리

일정과 무관한 잡담이면 「없음」으로 끝냄

↓

파인튜닝 E4B 호출 674번

혼자 다 풀면 835번



맞힌 문제 수 / 769

읽는 법

748 대 745 는 구분되지 않습니다(갈린 문제 3 : 6, p=0.51).

697 은 파인튜닝 안 한 모델을 파인튜닝한 모델과 이은 결과라 공정한 비교가 아닙니다. 같은 방법으로 파인튜닝한 두 모델을 섞은 구조는 747~752로 혼자와 구분되지 않았습니다.

라우터 = 질문을 어느 모델로 보낼지 고르는 단계. 697 은 시험 문제 일부를 본 뒤 고친 사후 수정 버전이고, 미리 고정한 버전은 472 였습니다. 표의 점수는 모두 AI 가 쓴 합성 문제 기준입니다.

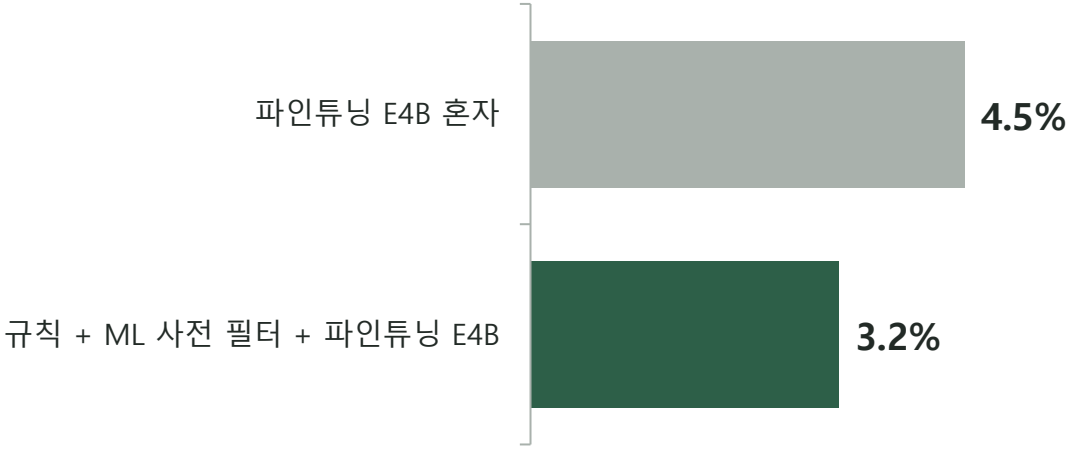
일정과 무관한 말이 섞이면, 앞단이 엉뚱한 일정을 고르는 실수를 줄였습니다

혼합 트래픽 테스트: 실제 채팅처럼 일정 질문 사이에 잡담 · 관광 질문을 섞은 2,735문제

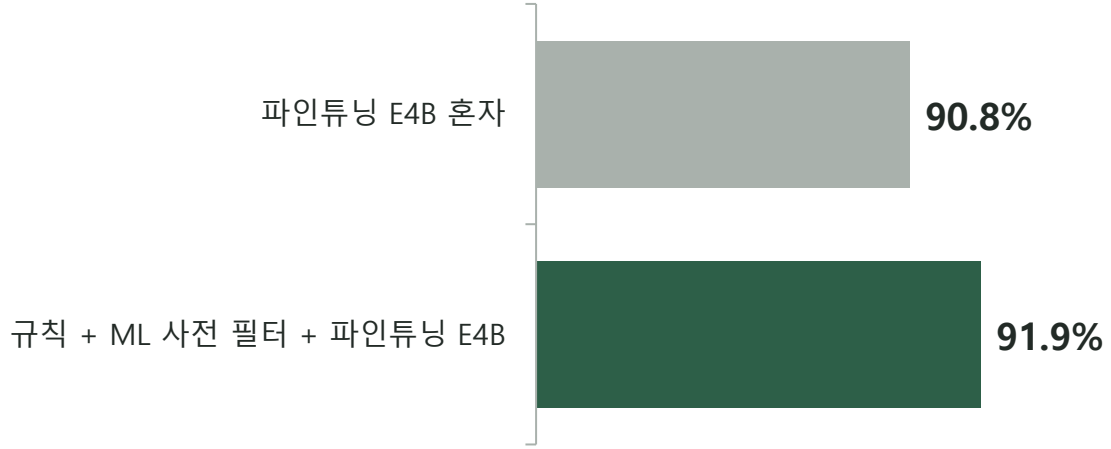
섞은 구성 (2,735문제)



일정과 무관한 말에 일정 항목을 잘못 고른 비율 (낮을수록 좋음)



전체 정답률 (높을수록 좋음)



일정과 무관한 말 1,786개 중 80 → 58개. 정답률은 복수 항목 질의를 뺀 2,669문제 기준 2,424 → 2,453개(갈린 문제 37 : 8, p=1.5e-5). 큰 모델 호출 2,735 → 2,117번. 빈 답 85건(3.1%)은 원인 미확인입니다.

고객 말 꼬리표 네 개 중 「얼마나 급한가」가 학습으로 가장 많이 올랐습니다

고객 말 분류: 한 문장에 의도 · 대상 · 감정 · 긴급도 꼬리표를 붙여 처리 순서와 담당을 정합니다

고객

식당 왔는데 우리 네 명 자리 없대요. 어떡하죠?

사건 신고	식당	부정	높음
의도	대상	감정	긴급도

이 장의 말

파인튜닝 전 E4B 학습 없이 지시문만 주고 꼬리표를 고르게 한 결과

학습한 분류 모델 문장을 숫자로 바꾸는 공개 모델(multilingual-e5-base)에 분류 층을 얹어 우리 문장 720개로 학습

시험 400문장 Codex 가 쓰고 Claude 가 따로 꼬리표를 달아 맞춰 본 합성 문장

긴급도 정확도 (400문장)



학습한 분류 모델의 나머지 꼬리표 정확도



분류 시험 CX 400(합성). 학습한 분류 모델은 작은 인코더라 지시문만 받은 E4B 와 조건이 달라 통제된 우열 비교는 아닙니다.

규정 검색은 고객용 문장 인덱싱으로 정답이 늘었지만 오응답도 늘었습니다

규정 검색(RAG): 고객 질문에 맞는 회사 규정 조각을 찾아 저장된 문장을 그대로 보여 줍니다

고객

창덕궁 임시 휴관이면 일정 어쩌죠?

정답 규정 조각

「운영 중단과 통제」 문서 · 「임시 휴관과 정기 휴관을 나눈다」 절

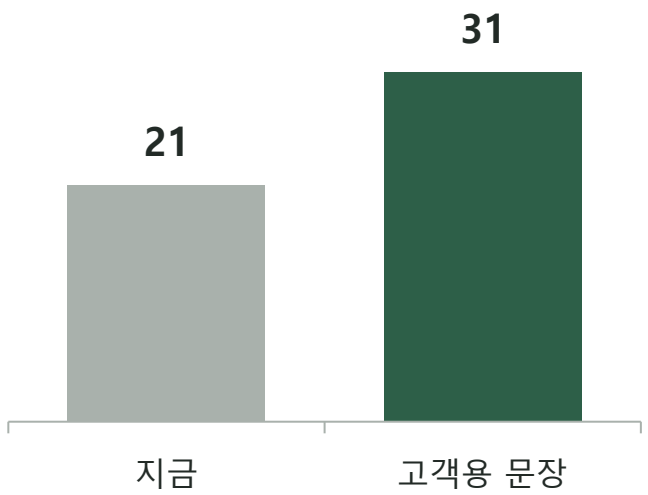
이 장의 말

인덱싱 텍스트 규정을 찾을 때 질문과 비교하는 글. 직원용 본문 → 「제목 + 절 제목 + 고객용 문장」으로 바꿔 봄

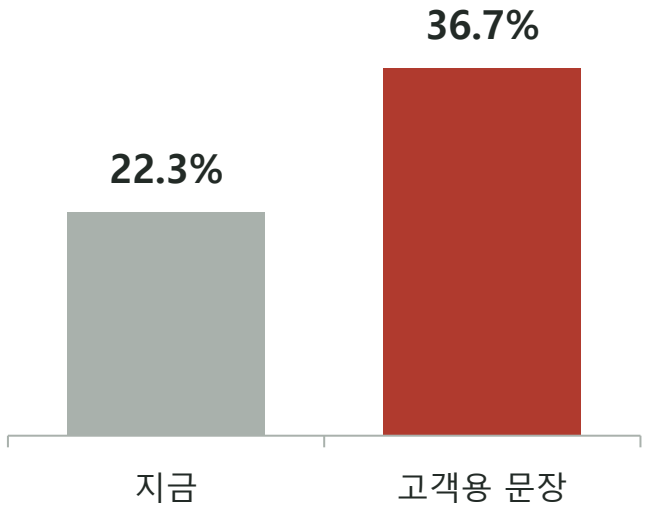
블라인드 평가셋 48문제 규정 문장을 보지 않고 따로 쓴 질문(AI 합성). 쉬운 개발용 세트와 나눠 이 세트를 기준으로 봄

오응답 규정 질문이 아닌 말에 규정을 붙여 보여 줌

정답 규정을 보인 질문 /48



여행 대화에 규정을 잘못 붙인 비율



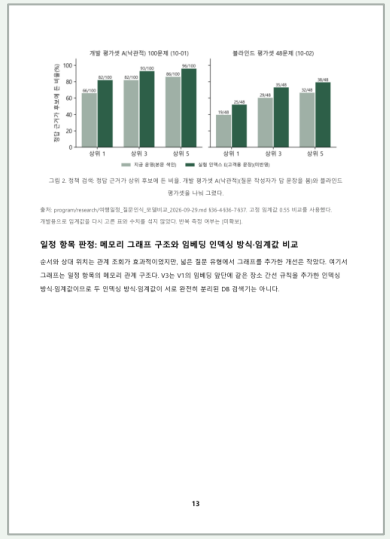
그래서 바로 넣지 않습니다

「일요일 08:44에 2명 예약해 주세요」 같은 예약 요청에도 규정이 붙었습니다. 제품에서는 앞의 분류 단계가 규정 질문만 이쪽으로 보내므로, 분류 뒤에서 다시 재고 정합니다.

지금 성능: 정답 규정이 상위 3개 안에 든 비율 30/48 = 62.5% (목표 90%)

2026-10-06, 제품의 규정 답 함수를 그대로 호출. 오응답 비율은 라벨 없는 여행 대화 300건 기준. 규정 문장은 모델이 쓰지 않고 저장된 문장을 그대로 실어 인용 정확도 334/334 입니다.

5주차 산출물 5종 · 6주차 보고서 1종, 모든 문서 첫머리에 용어 정의



벡터DB · GraphDB 구축 결과서

검색 성능 · 저장소별 쓰임

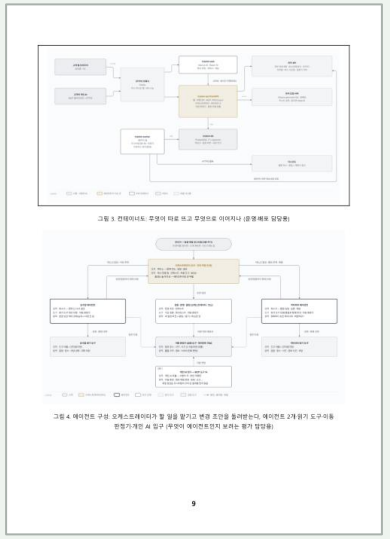
24쪽



멀티 에이전트 테스트 계획 및 결과 보고서

파인튜닝 · E2E 테스트

55쪽



AI 시스템 아키텍처

구성도 · 흐름 · 장애 대응

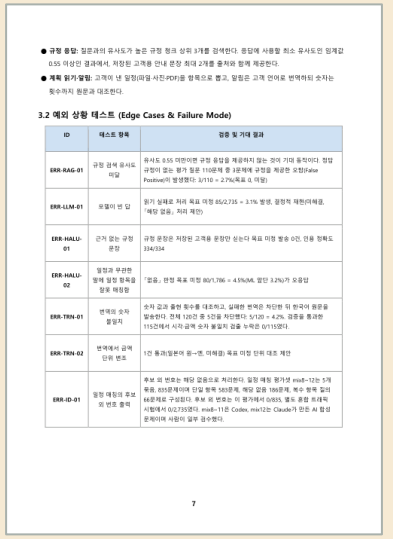
28쪽



화면설계서

화면 12개 · 흐름

25쪽



서비스 테스트 계획 및 결과 보고서(6주차)

Pass/Fail · 결함 대장

23쪽

요구사항 정의서 85개

구현 끝 24

일부 구현 58

결정 대기 3

모든 문서를 코덱스와 교차 검증했고, 우리끼리 쓰던 말(한 줄 시험 · 요청 둘 · 독립 세트 등)을 실무 용어로 바꾼 뒤 1절 맨 앞에 「읽기 전에: 용어 정의」 표를 두었습니다.

남은 문제도 숫자로 드러나 있습니다

왼쪽 숫자가 지금 값, 오른쪽 회색이 목표입니다

0건 목표 35행

사람 평가

실제 사람이 답을 읽고 매긴 점수가 아직 없음. 평가 시트 35행만 준비

62.5% 목표 90%

규정 검색 상위 3개 안 정답

블라인드 평가셋 30/48

3.1% 목표 0%

일정 항목 찾기 빈 답

모델이 아무 답도 안 낸 경우 85/2,735. 원인 미확인

1/172 목표 0

엉뚱한 일정을 바꾸려 함

채팅 한마디를 할 일로 바꿀 때 다른 항목을 고른 1건

1건 목표 0

알림 번역 금액 단위 바뀜

일본어로 옮기며 「35,000원」→「35,000円」, 숫자만 대조하는 검사를 통과

3.4% 목표 0%

계획 읽기 값 지어냄

원문에 없는 제목 · 예약번호를 뽑은 경우 12/350

모든 값은 AI 가 쓴 합성 시험 기준입니다(사람이 쓴 실제 고객 문장 시험은 아직 없음).

다음 주에는 실서버 확인과 사람 평가로 합성 점수의 빈칸을 메웁니다

지금 막힌 것	다음 주에 할 것
바뀐 화면 대부분 실서버 확인 안 함	**x600 서버의 cs 프로젝트 서버에서 바뀐 화면을 실제로 확인**
사람 평가 0건	**평가 시트 35행으로 사람 평가 진행**
4B 모델끼리 순위 미정 · 제품 미연결	**시드 3개 이상으로 다시 학습해 순위 확인, 제품 연결 검토**
규정 검색 62.5% · 오응답 증가	**고객용 문장 인덱싱을 분류 단계 뒤에서 다시 재고 결정**
다른 Jev 계열 후보 미시험	**Plumb-4B 등 3종을 같은 방법으로 파인튜닝해 비교 (GPU 서버 B)**

부록. 이 발표의 시험 · 자료 · 구성 이름

팀이 붙인 이름만 모았습니다(표준 기술 용어는 풀지 않음)

mock 서버	서버 응답 모양만 흉내 내는 시험용 대역 서버
cs 프로젝트 서버	고객 요청을 처리하는 triPilot 앱(api · worker · web · db)
x600 서버	cs 프로젝트 서버가 올라가 있는 팀 기계
GPU 서버 A · B · C	모델 학습 · 시험용으로 빌린 원격 GPU 기계
항로 지킴이	문제가 생기면 서비스가 먼저 바꿔 두고 알릴지 고르는 스위치
Jev 계열 모델	선택지 중 하나를 고르는 결정 전용 공개 모델 묶음(Winnow-E4B 등)
Jev API(유료)	같은 계열의 종량 과금 외부 결정 API
시험 세트 mix8~12	일정 항목 매칭 5묶음 835문제(AI 합성). mix8~11 Codex · mix12 Claude 작성
769문제	835문제에서 복수 항목 질의 66문제를 뺀 주 지표 분모

복수 항목 질의	한 문장에 일정 항목 두 개를 묻는 질문
B · C 채점	B: 복수 항목 질의는 하나라도 맞으면 정답 · C: 낸 항목 묶음이 정답 묶음과 완전히 같아야 정답
E2E 파이프라인 테스트	규칙 → ML 사전 필터 → 라우터 → 파인튜닝 E4B 를 문제마다 실제로 이어 부른 시험
ML 사전 필터	일정과 무관한 잡담을 먼저 거르는 작은 분류 모델(multilingual-e5-base 기반)
혼합 트래픽 테스트	일정 질문 835 + 관광지 질문 600 + 일상 대화 1,000 + 구어체 300 = 2,735문제
블라인드 평가셋 B	규정 문장을 보지 않고 따로 쓴 규정 질문 160문제(답 있는 48)
CX 400	고객 문장 분류 평가셋 400문장(Codex 작성 · Claude 교차 라벨)
인덱싱 텍스트	규정을 찾을 때 질문과 비교하는 글(직원용 본문 → 고객용 문장으로 바꿔 봄)
합성 문제	사람이 아니라 AI 모델(Codex · Claude)이 쓴 시험 문장