triPilot

WEEK 5 STANDUP · SKN32 6팀 A-COPilot

5주차 진행 경과

자유여행자가 올린 여행 계획을
여행이 끝날 때까지 지켜 주는 서비스



2026.09.29 ~ 10.06

AGENDA

오늘은 다섯 파트로 말씀드립니다

01	서비스	하는 일 · 유스케이스 · 아키텍처 · 한 주 규모 · 화면 · 서버 · 이동 · 에이전트 · 배포
02	모델	모델이 푸는 문제 · 파인튜닝 방법과 검증 · 시험 A · B · C · D
03	비용	상용 모델과 비교 · 손익 분기 · 단계별 전환 계획
04	검증	여러 단계 잇기 · 혼합 트래픽 · 분류 · 규정 검색 · 사람 검수 · 측정 방법
05	남은 일	해결한 것과 남은 것 · 다음 주

HOW IT WORKS

계획을 받아 여행이 끝날 때까지 지킵니다

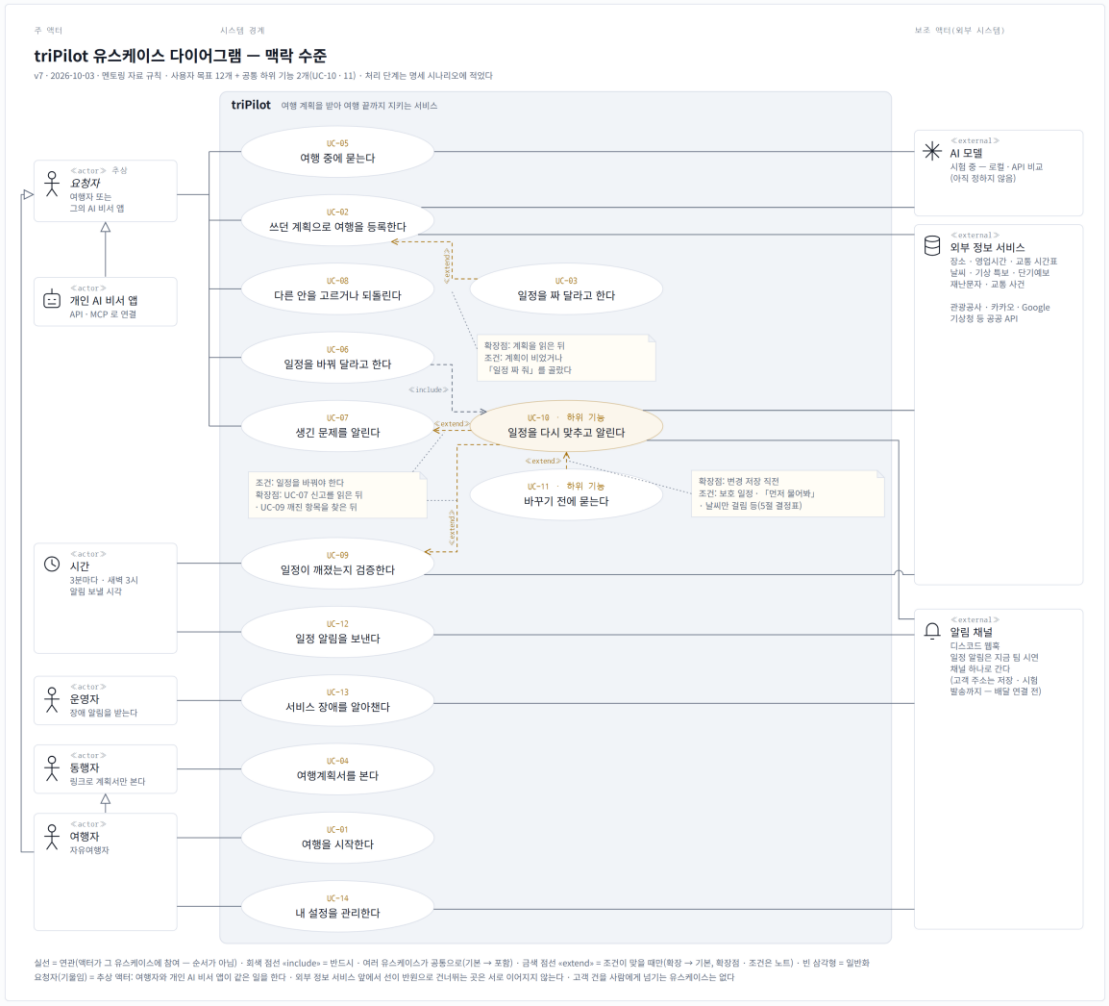


이번 주에 손댄 곳

- **화면 12개를 cs 프로젝트 서버에 연결**
  계획 올리기부터 재난 시 일정 정지까지
- **실시간 진행 표시 · 개인 AI 입구**
  오래 걸리는 일의 단계 표시 · 본인 여행만
- **고객 말 → 일정 항목 매칭 모델**
  파인튜닝 시험 중 · 제품 미연결

「아키텍처 한눈에 v26」 그림 1 · 4 를 줄인 흐름입니다. 알림은 디스코드 등으로 보내고, 바뀐 내용은 로그인 없이 열리는 여행계획서 링크에도 반영됩니다.

고객 목표 12개와 공통 하위 기능 2개로 정리했습니다



누가 쓰나

여행자 · 개인 AI 비서 앱(같은 일을 함) · 동행자(계획서 링크만) · 시간(3분마다 점검) · 운영자(장애 알림)

무엇을 하나

계획으로 여행 등록 · 일정 짜 달라 · 여행 중에 묻기 · 일정 바꿔 달라 · 생긴 문제 알림 · 다른 안 고르기 · 되돌리기

공통 하위 기능

일정을 다시 맞추고 알린다 · 바꾸기 전에 묻는다(보호 일정 · 「먼저 물어봐」일 때)

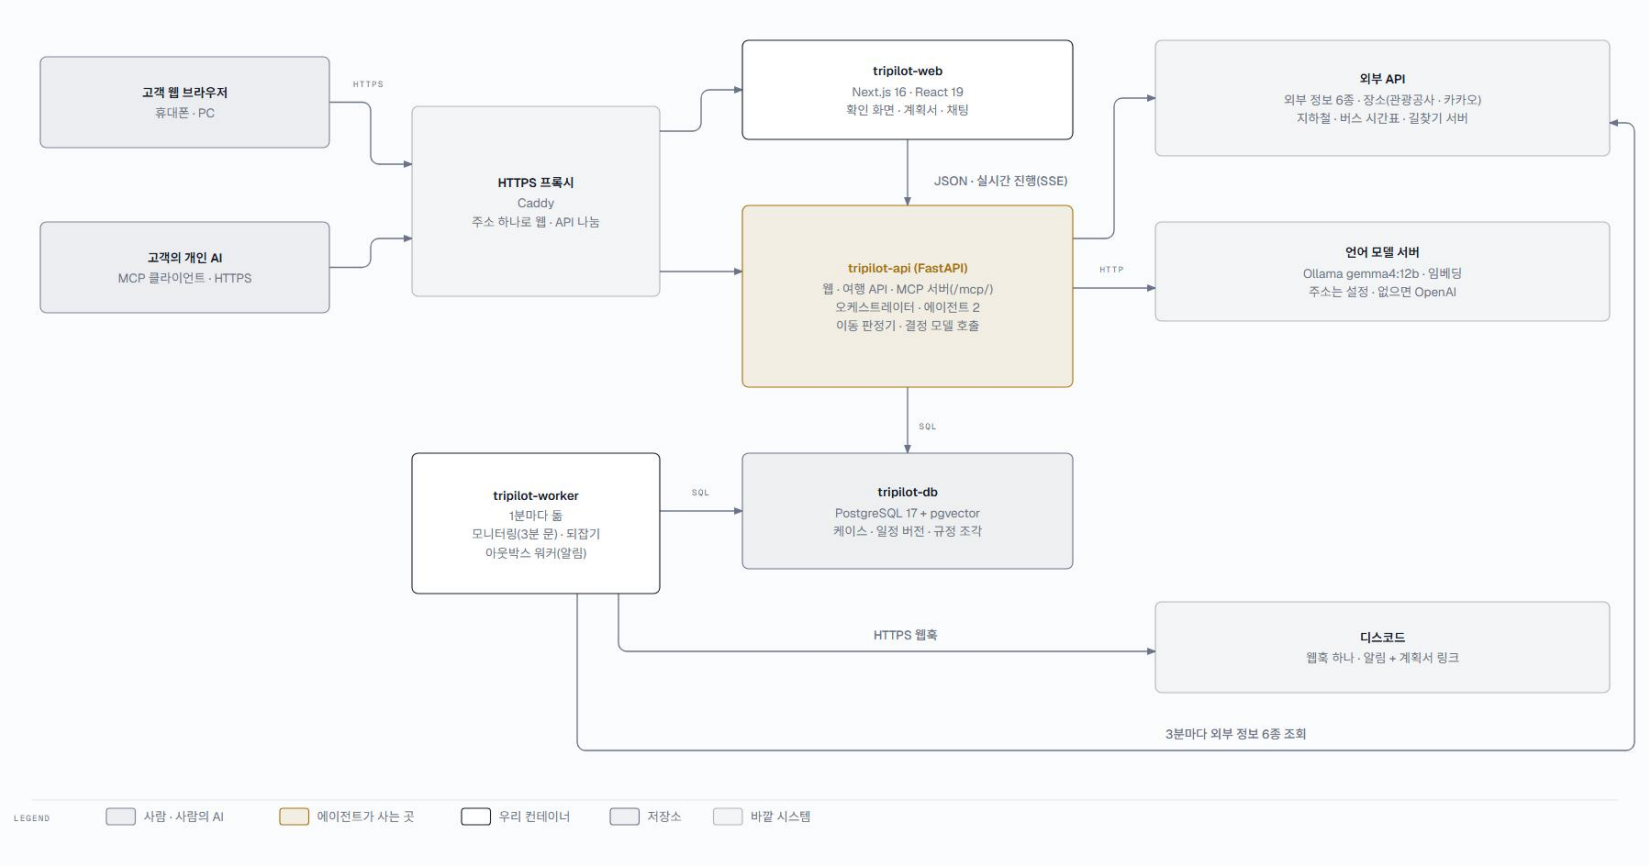
하지 않는 것

고객 건을 사람 상담원에게 넘기는 유스케이스는 없습니다

유스케이스 명세 v7(22쪽, 10-03) · 처리 단계는 명세의 시나리오에 적었습니다. 실선 = 참여, 점선 = 포함 · 확장.

SYSTEM ARCHITECTURE

두 입구가 API 하나로 모이고, 워커가 3분마다 일정을 지킵니다



입구 둘

고객 웹(Next.js) · 고객의 개인 AI(MCP)

API 하나

FastAPI 안에 오케스트레이터 · 요식업 · 액티비티 에이전트 · 이동 판정

워커

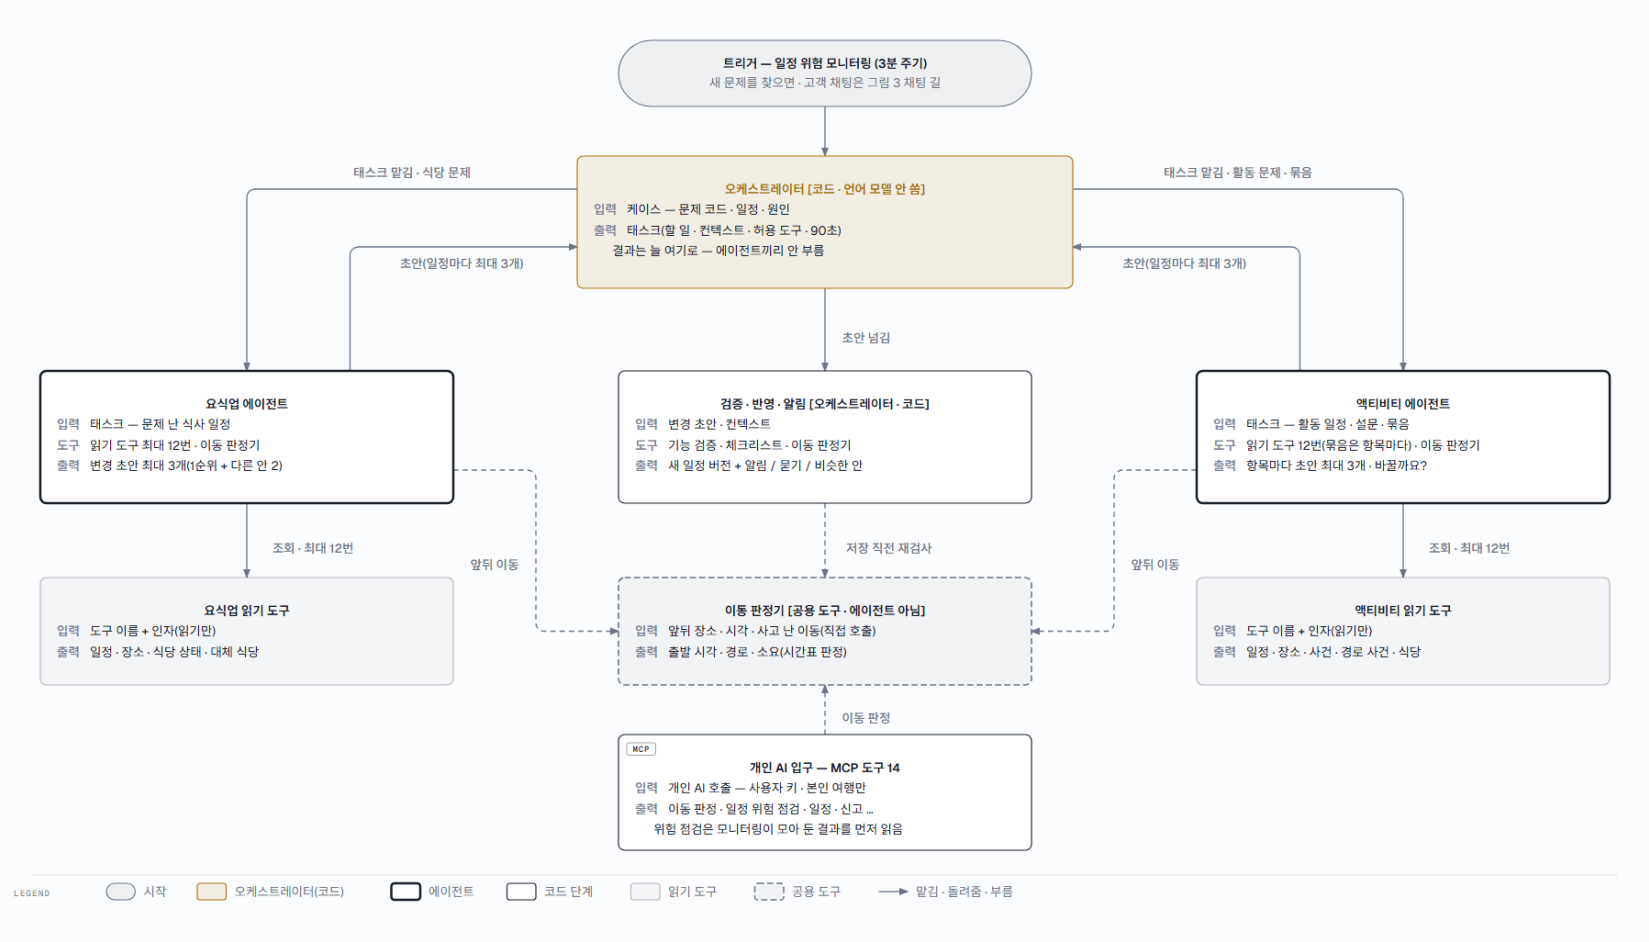
1분마다 돌며 3분마다 외부 정보 6종 조회 · 알림 발송

모델 · 저장

Ollama gemma4:12b · 임베딩 / PostgreSQL + pgvector

AI 시스템 아키텍처 문서(28쪽 · 그림 10장)의 그림 2. 컨테이너 4개(웹 · API · 워커 · DB)가 x600 서버에서 돌고 있습니다.

오케스트레이터는 코드로 맡기고 검증하며, 두 에이전트는 초안만 냅니다



오케스트레이터

언어 모델을 쓰지 않는 코드 · 일을 맡기고 결과는 늘 여기로

에이전트 2개

요식업 · 액티비티 · 일정마다 바꿀 초안 최대 3개

검증 · 반영

체크리스트 · 이동 판정으로 다시 본 뒤 저장 · 알림

이동 판정

에이전트가 아닌 공용 도구 · 앞뒤 일정 시간표 판정

AI 시스템 아키텍처 문서의 그림 3. 에이전트끼리는 서로 부르지 않고, 읽기 도구는 한 번에 최대 12번까지 씁니다.

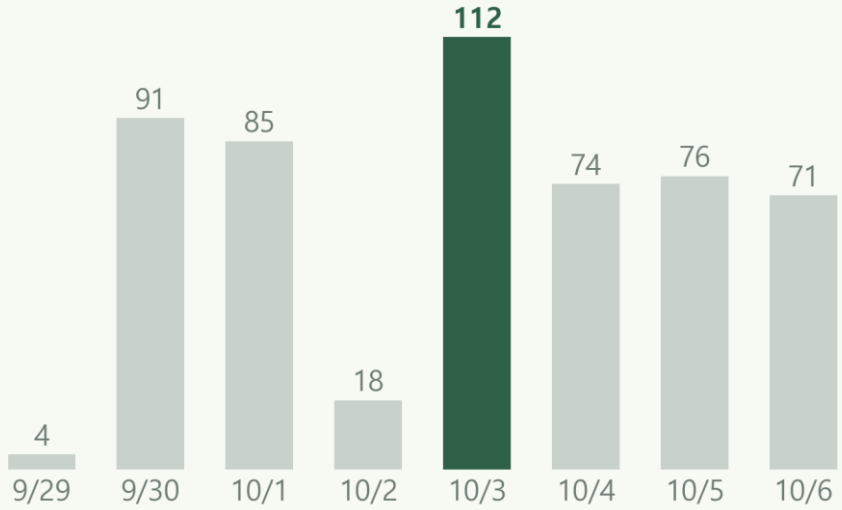
THIS WEEK

한 주 동안 커밋 531건을 쌓았습니다

531

커밋 · 모든 브랜치(팀원 포함)

작업 브랜치만 세면 402건



git log 2026-09-29 ~ 10-06. 막대 진한 색은 가장 많은 날(10/3, 112건).

12

고객 웹 화면 연결

계획 올리기부터 재난 시 일정 정지까지

4,245 / 4,251

자동 시험 통과 (99.9%)

10-06 18:09, 실제 모델 시험 238개 제외

688 → 760

일정 항목 매칭, 769문제 중

약 4B 모델 파인튜닝 전 → 후(2회차)

22쪽 · 28쪽

유스케이스 · AI 시스템 아키텍처 완성

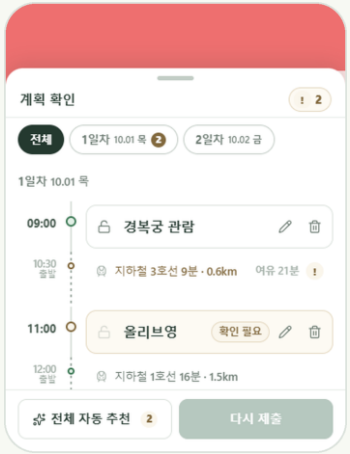
유스케이스 v7 · 아키텍처는 양식 6절 · 그림 10장 · 코드 대조 20건

고객이 지나가는 여섯 단계를 이어 붙였습니다













01
계획 올리기
글 · 사진 · 파일

02
계획 읽는 중
기다리는 동안 취향 질문

03
항로 지킴이
먼저 바꿀지 고르는 스위치

04
계획 확인
날짜별 일정 · 수정

05
여행 화면
일정 · 지도 · 채팅 · 알림

06
재난 시 일정 정지
안전 안내 · 119 · 대피 장소

mock 서버 시험 397/402(화면 반응). 실서버 확인(10-07): x600 서버의 cs 프로젝트 서버 응답 · 웹 경로 55개 · 재난 뒤 패널 문구까지. 로그인 · 여행 만들기 흐름은 아직입니다.

AI 비서 입구와 실시간 진행 표시가 생겼습니다

개인 AI 입구

고객의 AI 비서 → triPilot 입구 → 본인 여행만

읽기 일정 · 위험 점검 결과 · 이동 판정 **켜짐**
고치기 일정 수정 · 신고 **기본 꺼짐**

15 / 15
자동 시험 통과
10-02 · 본인 여행만 열리는지 · 꺼진 고치기가 막히는지

실시간 진행 표시



수십 초 걸리는 일(계획 읽기 · 일정 짜기 · 채팅) 동안 지금 몇 단계인지와 3초마다 「살아 있음」 신호를 보냅니다.

21 / 21
자동 시험 통과
10-02 · 채팅 · 일정 짜기 · 계획 읽기

10 / 10
에이전트 다시 고르기
맡을 에이전트가 없을 때 한 번 더 고름 · mock 서버 시험

517 / 517
요식업 에이전트 시험
팀원 정세환 · 10-06

개인 AI 입구는 MCP 서버입니다. 디스코드 · 텔레그램 연결과 여행 삭제는 코드에 들어갔지만 x600 서버 반영과 실제 연결은 아직 확인하지 않았습니다.

이동 판정을 구글 · 카카오 길찾기와 맞춰 보며 차이를 줄였습니다

이번 주에 넣은 것

10-01 **가장 이른 도착 계산**
앞 일정이 끝난 뒤 출발해서 되는 가장 이른 도착 · 시험 45건

10-01 **지하철 ↔ 버스 섞기**
환승 1회 · 80구간 중 6구간에서 새 선택지, 기존 80/80 그대로

10-06 **걷기 거리 상한**
직선의 2배까지만 · 멀리 도는 출구 대신 다른 출구

10-06 **버스 → 버스 환승 후보**
구글이 고른 3구간에서 후보 생성 · 작업 중

10-06 **역과 지하로 이어진 건물**
126개 역 · 216개 통로 · 작업 중

대중교통 · 구글 Routes 17구간

+3.5 → +3.0분

구글보다 긴 정도(중앙값) · 절대오차 5.7 → 5.3분

걷기 거리 부풀림 · 83곳

8 → 3곳

직선의 2배 넘는 걷기 · 예: 남대문시장 → 시청 4,065m → 824m

택시 · 카카오 미래 길찾기 12쌍

0.92 · 1.08 · 0.96

거리 · 시간 · 요금 비율(우리 ÷ 카카오) · 요금은 ODsay 와 9/9 같음

카카오는 대중교통 길찾기 공개 API 가 없고 도보는 권한 거부라, 대중교통은 구글과 · 택시는 카카오와 대조했습니다. 17구간은 작아 「나아졌다」보다 「방향이 맞다」로 읽습니다. 작업 중 2건은 커밋 전.

요식업 · 액티비티 에이전트는 팀 작업을 합치고 데이터를 늘렸습니다

요식업 에이전트

990 → 1,599곳

서울 음식점 목록

· 팀 작업 합침: 파일 66/66 · 시험 2,525 + 496 통과
· 사업자 등록 영업 15만 곳 적재(좌표 오차 중앙 6m)
· 폐업 판정에는 안 씀 — 사람 확인 46곳 중 22곳 불일치

액티비티 에이전트

2,454 / 2,455

자동 시험 통과

· 팀 작업 중 나은 것 4/4 반영
· 다른 브랜치 83줄 판정: 반영 2 · 일부 8 · 제외 73
· 같은 브랜드 매장 364행 추가

오케스트레이터

10 + 847

다시 고르기 시험 · 흐름 시험 통과

· 맡을 에이전트가 없으면 등록된 에이전트 안에서 한 번 더 고름
· 그 뒤 Case 가 죽던 결함 수정(10-07)
· AI 비서 입구에 읽기 도구 2개 · 시험 60건

계획 읽기

90.2 → 97.0%

일정 항목을 빠짐없이 읽은 비율(336항목)

· 근거 없는 값 0 / 1,828
· 사진 · 스캔 글자 오독 12/350 — 고치는 중
· 읽는 동안 진행 알림 · 추천 미리 보기

숫자는 각 담당 세션의 리포트 · 자동 시험 기준입니다. x600 서버에서 실제 고객 흐름까지 확인한 것은 아닙니다. 팀원 작업은 「팀 작업」으로 적었습니다.

올리면 x600 서버에 자동 반영되고, 실패하면 이전 판으로 돌아갑니다

시험 · GitHub Actions (09-24~)

develop · main 에 올리면 린트 · 구조 · 단위 · 보안 시험, main 은 전체 시험 + Docker 빌드까지

배포 · x600 서버 자동 반영 (10-03~)

1. **5분마다 새 커밋 확인**
   팀 저장소 작업 브랜치 · 올린 뒤 2~10분 안에 반영
2. **바뀐 부분만 이미지 빌드**
   커밋 번호로 이름 · 이전 판 3개 보관
3. **DB 변경 → 새 판 띄움**
   DB 변경은 앞으로만 적용
4. **30초 지켜봄**
   컨테이너 4개 · 재시작 0 이면 성공

실패하면 이전 판으로 되돌리고 그 커밋은 다시 안 씀

실제로 10-06 DB 변경 교착으로 실패 → 서비스는 이전 판으로 계속 → 고친 커밋으로 반영. 지금 판 9a3521b5(10-07) · 상태 확인 200

확보한 서버

x600 서버	**팀 기계 · 12GB GPU · Docker** 공개 서비스(DB · API · 워커 · 웹) + 모델 2개
오라클 무료 서버	**ARM 2코어 · 12GB · 0원** 적은 질문 운영 후보 · CPU 추론 실측
RunPod GPU A	**RTX 2000 Ada 16GB** 모델 20여 종 채점
RunPod GPU B	**RTX A4000 · 16 vCPU · 62GB** 파인튜닝 · 모델 변환
RunPod GPU C	**RTX 4000 Ada 20GB** E2E 파이프라인 테스트 · 10-06 반납
경유 서버	**고정 IP** IP 에 묶인 도로 통제 API 호출

지금 x600 서버에서 돌고 있는 서비스

https://tripilot.devroro.click

QR 로 휴대폰에서 바로 열 수 있습니다

자동 반영은 x600 서버가 스스로 새 커밋을 확인하는 방식(웹훅 아님). GitHub Actions 는 시험만 하고 배포는 하지 않습니다. AWS 는 확보하지 않고 비용 비교만 했습니다.

THE MODEL TASK

고객 말이 일정표의 몇 번 항목인지 찾습니다

금요일 일정 · 2027-11-05

23	13:30	대림미술관 전시 관람
24	15:30	호텔 체크인
25	16:30	**피크닉 전시 보기**

고객
금요일에 전시 뭐 봐?

triPilot
13:30 대림미술관, 16:30 피크닉 전시가 있어요.

고객
뒤에 거 예매해야 돼?

→ **정답 25번**

고객
남산타워 몇 시에 올라가?

→ **정답 없음**

일정에 없는 곳은 지어내지 않음

769문제

시험 세트 mix8~12 835문제에서
한 문장에 두 항목을 묻는 66문제를 뺀 주 지표

11가지

헷갈리게 만든 유형: 「거기」 · 비슷한 이름 · 「~말고」 · 오타 · 잡담 · 없는 일정 등

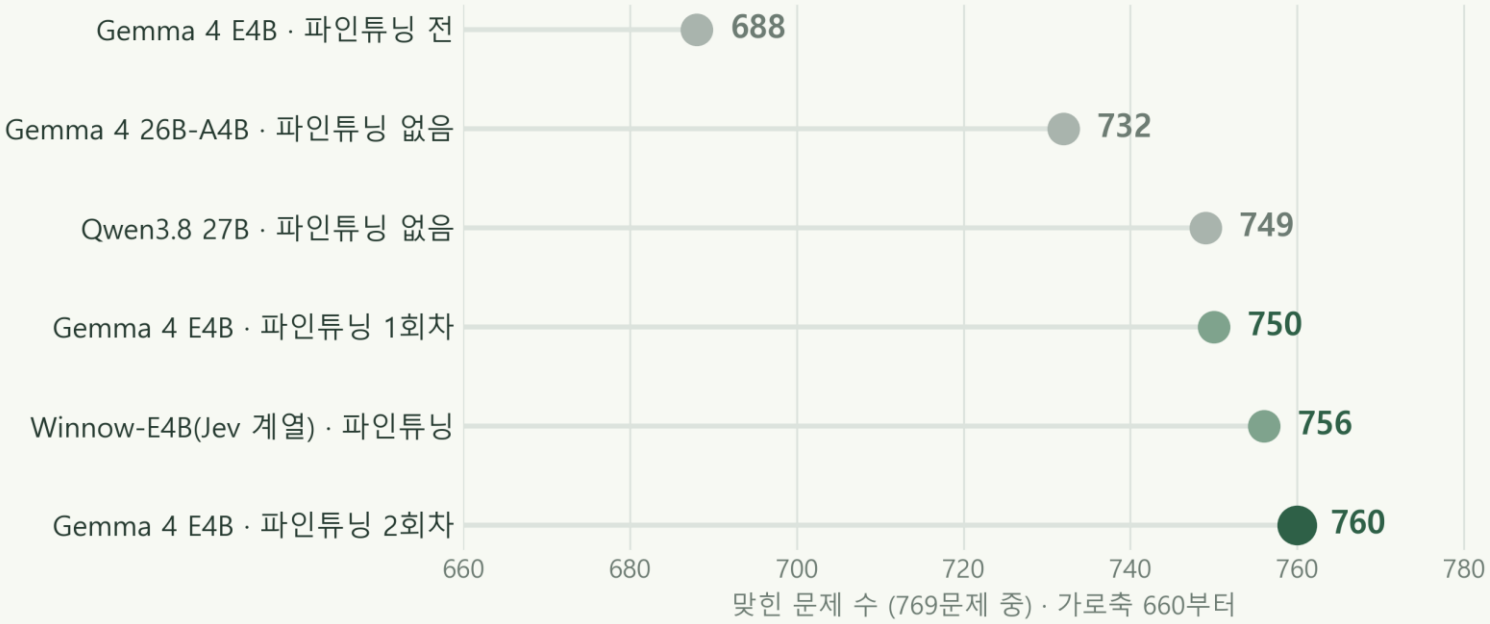
AI 합성

Codex · Claude 가 쓴 문제.
처음 문제 · 체크리스트는 사람이 쓰고 일부 검수

FINE-TUNING

4B 모델을 파인튜닝하니 27B 로컬 모델만큼 맞혔습니다

같은 769문제 · 맞힌 문제 수



파인튜닝 전 → 후

688 → 750

시드 1 기준 갈린 문제 69 : 7 (p=6.4e-14).
시드 3개 750 · 760 · 748 (평균 752.7) —
12문제가 흔들려 4B 모델끼리 순위는 안 매김.

0.24초

GPU 한 장(RTX 2000 Ada)

이어지는 질문 · 새 일정 첫 질문 1.1초 · CPU 4코어는 4.55초

학습 자료: 연습문제 1,760개(처음 문제 · 체크리스트는 사람이 쓰고 Claude 가 늘림). CPU 실행본(8비트 · 756/769)을 4비트로 줄여도 756/769 로 같음. Winnow-E4B 는 Jev 계열 결정 모델을 같은 방법으로 파인튜닝한 값.

Gemma 4 E4B 를 이렇게 가르치고 이렇게 검증했습니다

사람
처음 문제 · 체크리스트 작성

→

Claude
여행자 10명 일정 + 연습문제 1,760개

→

별도 풀이
정답 1,760/1,760 일치

→

겹침 제거
시험 문제와 같거나 비슷한 122개 뺌

→

나누기
학습 1,313 · 여행자 8명
검증 325 · 다른 2명

학습 설정 (평가를 보기 전에 하나로 고정)

기초 모델	google/gemma-4-E4B-it · 4비트 NF4
방법	QLoRA · LoRA rank 16 · alpha 32 · 선형층 7종
최적화	AdamW · 학습률 2e-4 · 2 epoch · 유효 배치 8
손실	정답 토큰에만
장비 · 시간	GPU 서버 B RTX A4000 16GB · 148.7분 · 최대 10.6GB

검증

320/325 — **검증 세트(학습에 없는 여행자 2명)**
파인튜닝 전 265 → 후 320

750/769 — **시험지 mix8~12 · 사전 등록 기준 통과**
전 688 → 후 750 · 갈린 문제 69 : 7 (p=6.4e-14) · 기준 +3%p · p<0.05

760/769 — **시드만 바꿔 다시 학습**
흔들림 10문제 → 모델끼리 순위는 시드 3개 이상

748/769 — **8비트 파일로 바꿔 CPU 4코어에서**
배포용 변환 뒤에도 구분 안 됨

시험지 mix8~12 는 학습 자료와 겹침을 뺀 별도 문제(AI 합성). 학습 자료와 mix12 를 같은 Claude 가 만들어 mix12 는 유리할 수 있습니다. 코드: program/scripts/plan_qa_bench/server/qlora_train.py

BENCHMARKS

같은 문제를 네 가지 기준으로 재고 모델마다 점수를 냈습니다

A 835문제 · 먼저 말한 항목 하나만 정답

둘을 묻는 66문제는 먼저 말한 항목 하나를 맞혀야 정답

B 835문제 · 하나라도 맞으면 정답

둘을 묻는 질문은 둘 중 하나만 맞혀도 정답 (주 채점)

C 835문제 · 둘 다 맞혀야 정답

낸 항목 묶음이 정답 묶음과 같아야 정답 (가장 엄격, 사전 등록)

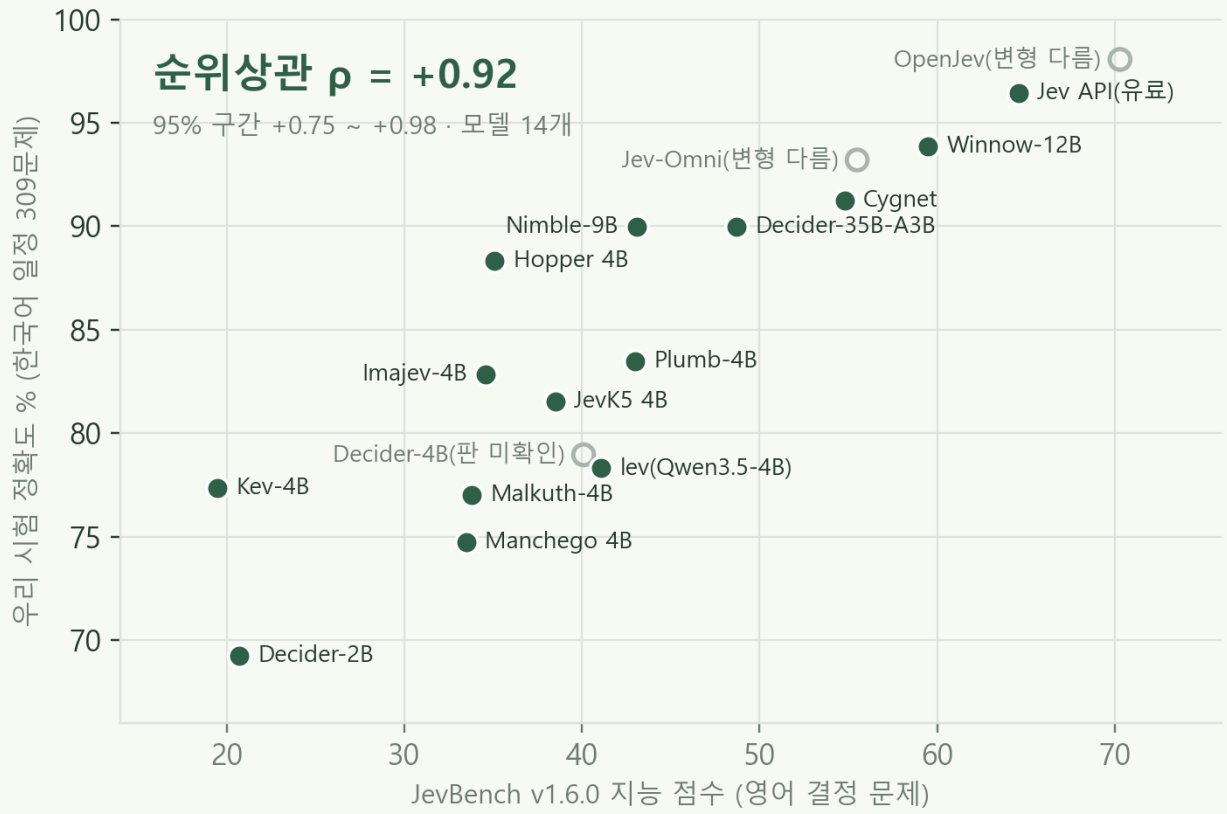
D 2,735문제 · 채팅처럼 섞음

835 + 관광지 질문 600 + 일상 대화 1,000 + 구어체 300

모델	769	A /835	B /835	C /835	D /2,669
Gemma 4 E4B · 파인튜닝 전	688	736	750	688	안 잼
Gemma 4 E4B · 파인튜닝 (시드 1)	**750**	**816**	**816**	**750**	**93.6% (시드 1)**
Gemma 4 E4B · 파인튜닝 (시드 2)	**760**	**825**	**826**	**760**	**90.1% (시드 3개 평균)**
Winnow-E4B(Jev 계열) · 파인튜닝	**756**	**821**	**821**	**756**	**안 잼**
Gemma 4 26B-A4B · 파인튜닝 없음	732	780	797	732	안 잼
Qwen3.8 27B · 파인튜닝 없음	749	793	814	749	못 잼 · 큰 GPU 필요
Claude Opus 5.5 · 상용	759	823	825	819	안 잼
Claude Fable 5.1 · 상용	762	825	828	821	안 잼
Codex Sol · Astra · Luna · 상용	760 · 766 · 741	없음	없음	814 · 823 · 793	안 잼

769 = 둘을 묻는 66문제를 뺀 주 지표. 우리 모델은 항목을 하나만 내는 구조라 C 에서 66문제를 놓칩니다. D 는 둘을 묻는 질문을 뺀 2,669문제를 생각 모드를 끄고 채점(지금은 파인튜닝 Gemma 4 E4B 만 잼 · 나머지는 RAG 세션이 재는 중). 상용은 CLI 실행 · 출제자 편향으로 공정 비교 아님, Codex 의 A · B 는 기록 없음.

외부 벤치마크와 모델 순위가 같은 방향입니다



무엇을 했나

학습 없는 원본 모델 14개를 우리 한국어 일정 시험(같은 309문제)으로 잰 순위와 공개 결정 벤치마크 JevBench v1.6.0(10-05 채점)의 순위를 견줬습니다.

무엇을 말하나

지능 점수와 순위상관 +0.92(95% 구간 +0.75~+0.98). 바깥 벤치마크와 모델 순서가 같다는 뜻으로, 우리 시험이 엉뚱한 것을 재지 않는다는 외부 근거 하나입니다(수렴 타당도). 측정 대상을 확정하지는 못합니다.

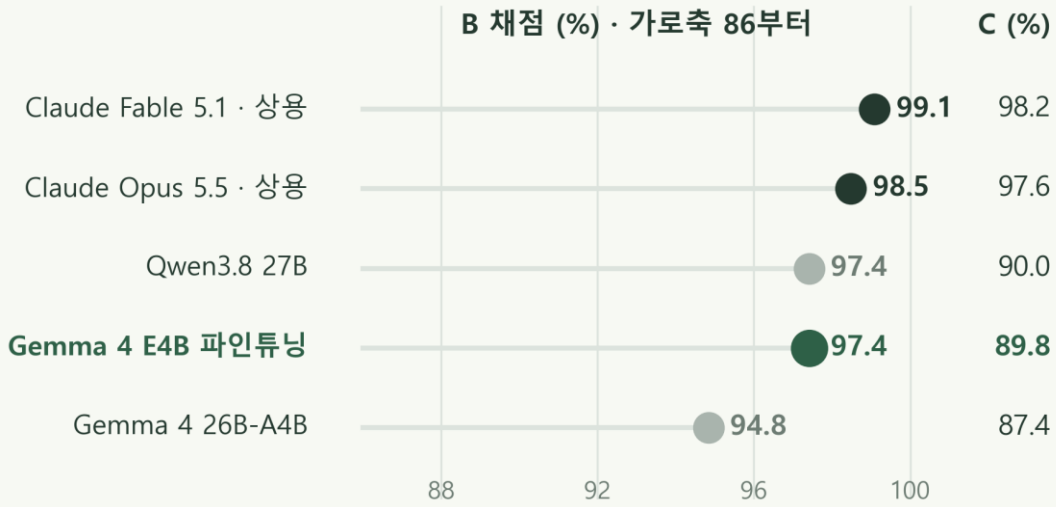
무엇은 말하지 않나

점수 크기는 이어지지 않습니다 — 보드 4B 상위 모델이 우리 시험에서는 78~84%. 속도 · 비용을 섞은 보드 헤드라인 점수와는 +0.66 으로 약합니다.

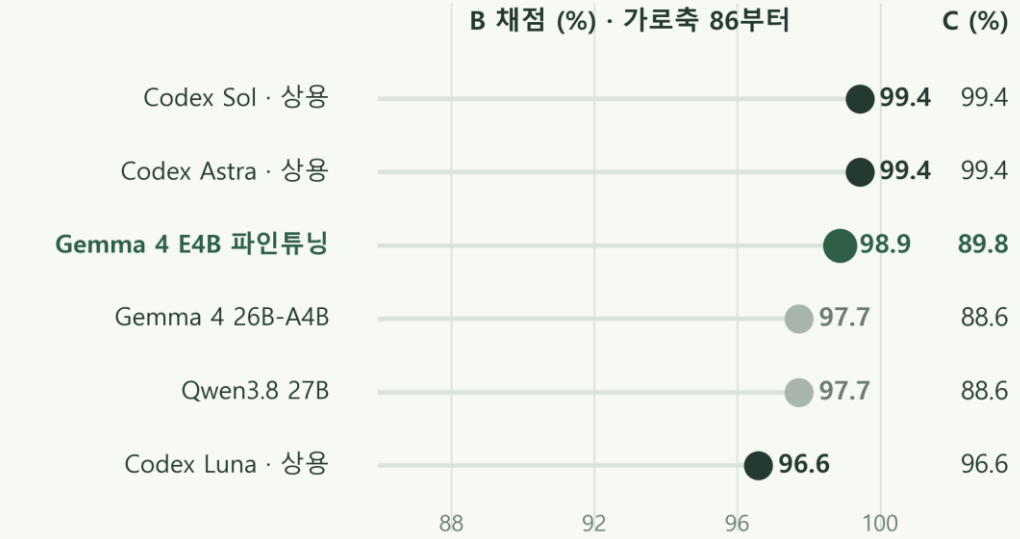
속이 빈 점 = 보드와 양자화 · 판이 다를 수 있는 모델(넣으면 지능 +0.93, n=17). 보드는 영어, 우리 시험은 한국어 · AI 합성 문제. 파인튜닝한 모델은 보드에 없어 대조하지 않았습니다.

점수는 상용 모델이 가장 높지만, 운영 비용이 문제입니다

Codex 가 쓴 659문제 · Codex 모델 제외



Claude 가 쓴 176문제 · Claude 모델 제외



운영 비용 (한 달)

상용 API 만 쓸 때

+5~10만원

상위 모델 사용량 과금 · 서버는 따로 필요

RunPod GPU 서버

25.6만원

A4000 · 16 vCPU · 62GB · 앱도 같이 · 월 고정

오라클 무료 서버

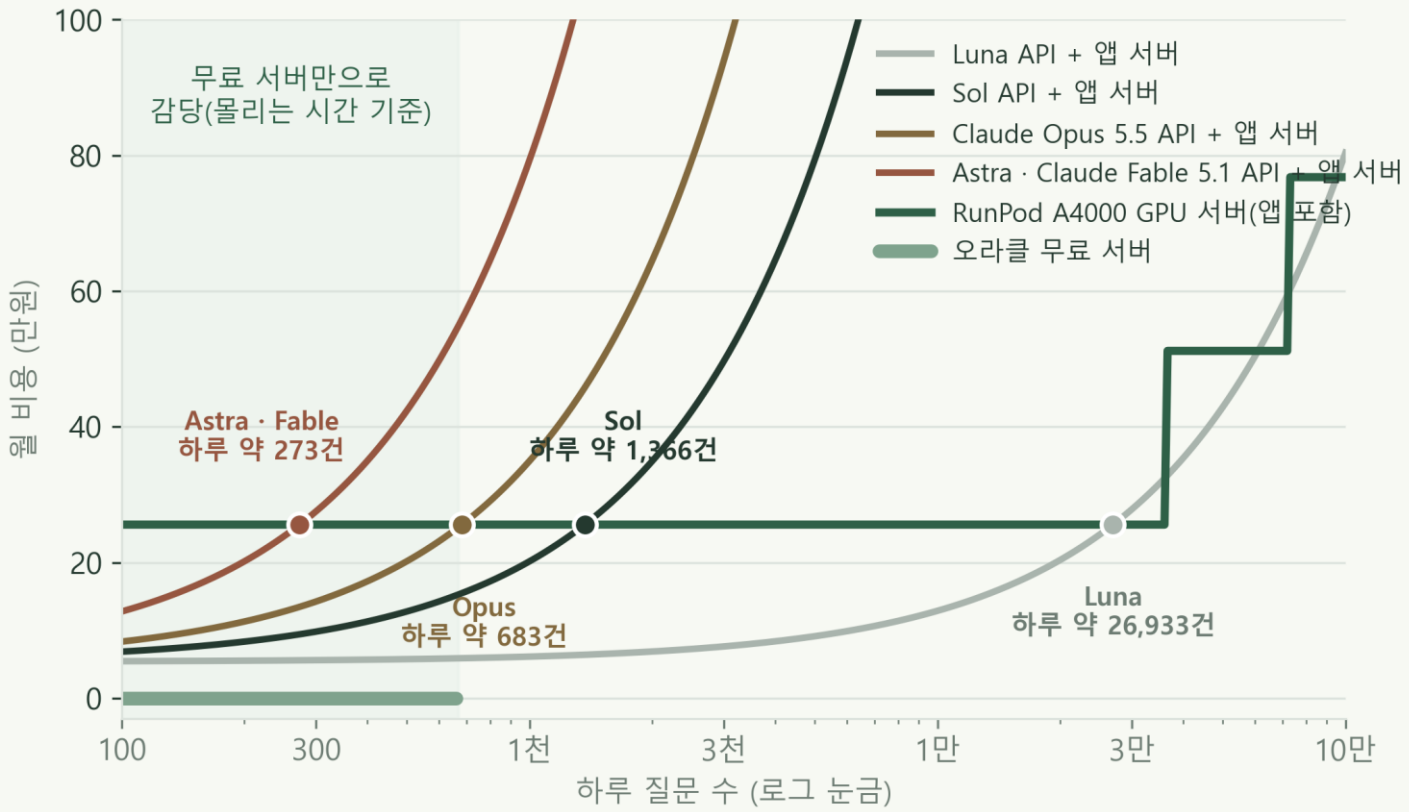
0원

2 CPU · 12GB · 몰리는 시간 기준 하루 약 700건

B: 둘 다 묻는 질문은 하나라도 맞으면 정답 · C: 묶음이 정답과 같아야 정답. 비용은 사용자 제공(10-07), 무료 서버 처리량은 측정 중.

COST BREAK-EVEN

하루 질문 수에 따라 가장 싼 방식이 바뀝니다



금액은 이렇게 나왔습니다

API 1건 입력 1,700 + 출력 12토큰 × 공식 단가 × 1,400원/달러
Luna 0.25 · Sol 4.93 · Opus 5.5 9.86 · Astra · Fable 5.1 24.64원

앱 서버 API 를 써도 서버는 필요 · AWS 서울 t3.medium 월 5.4만원

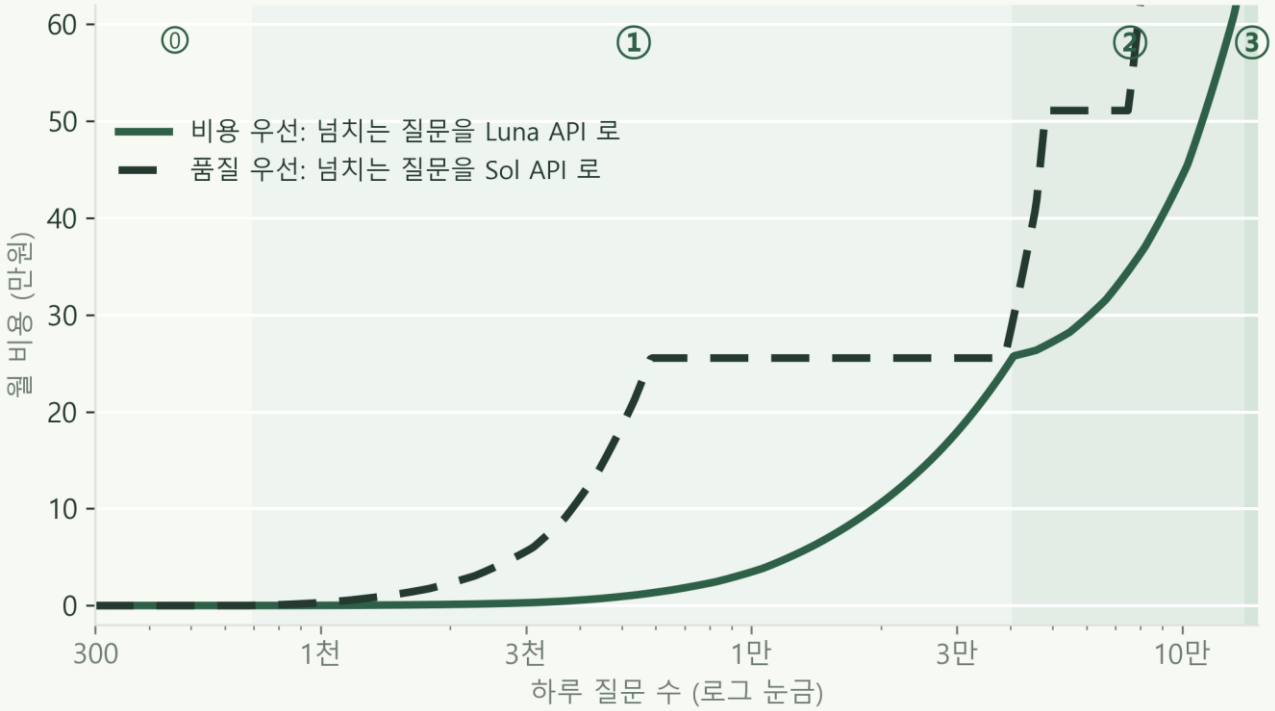
RunPod A4000 $0.25 × 730시간 = 월 25.6만원(앱 포함)
하루 약 3.6만 건 · 3 · 6개월 선불 약정 할인

오라클 무료 2코어 ARM · 12GB · 월 10TB = 0원 · 트래픽은 약 12억 건
실측: 이어지는 질문 7.7초 · 새 일정 112.5초 · 몰리는 시간 기준 하루 약 700건

읽는 법 한 가지 방식만 쓸 때의 비교입니다. 실제로는 섞어 쓰며, 질문 수별 가장 싼 조합은 다음 장에 있습니다.

단가: Claude · OpenAI 공식 가격 페이지(10-07 확인), 생각 토큰 · 캐시는 뺀 값. 「API 만 쓰면 월 5~10만원」은 Luna + 앱 서버 하루 1천~5천 건(6.1~9.1만원)과 맞습니다. 트래픽은 CPU 보다 한참 뒤에 막힙니다.

몰리는 시간 기준: 무료 서버만 → +API → GPU → 증설



비용 우선 경로 (넘치는 질문은 Luna API)

⓪	~700	**무료 서버만** 몰리는 시간까지 무료 서버가 다 받음 · 일정은 미리 읽음	**0원**
①	700~4.1만	**무료 서버 + API** 몰리는 시간에 넘치는 몫만 Luna API · 한가한 시간은 무료 서버	**0~25.7만원**
②	4.1만~14.0만	**GPU 1대 + API** API 비용이 GPU 월세를 넘는 지점에서 GPU · 피크 넘침은 API	**25.8~66.9만원**
③	14.0만~	**GPU 2대 → 반복** 하루 약 10만 건 늘 때마다 GPU 1대 추가	**66.9만원~**

품질 우선 경로 (Sol API)

⓪ 하루 700건까지 무료 서버만(0원)
① 5.9천 건까지 + Sol · ② 그 위로 GPU 1대(25.6만원)
③ 3.9만 건부터 약 3.8만 건마다 GPU 1대 추가

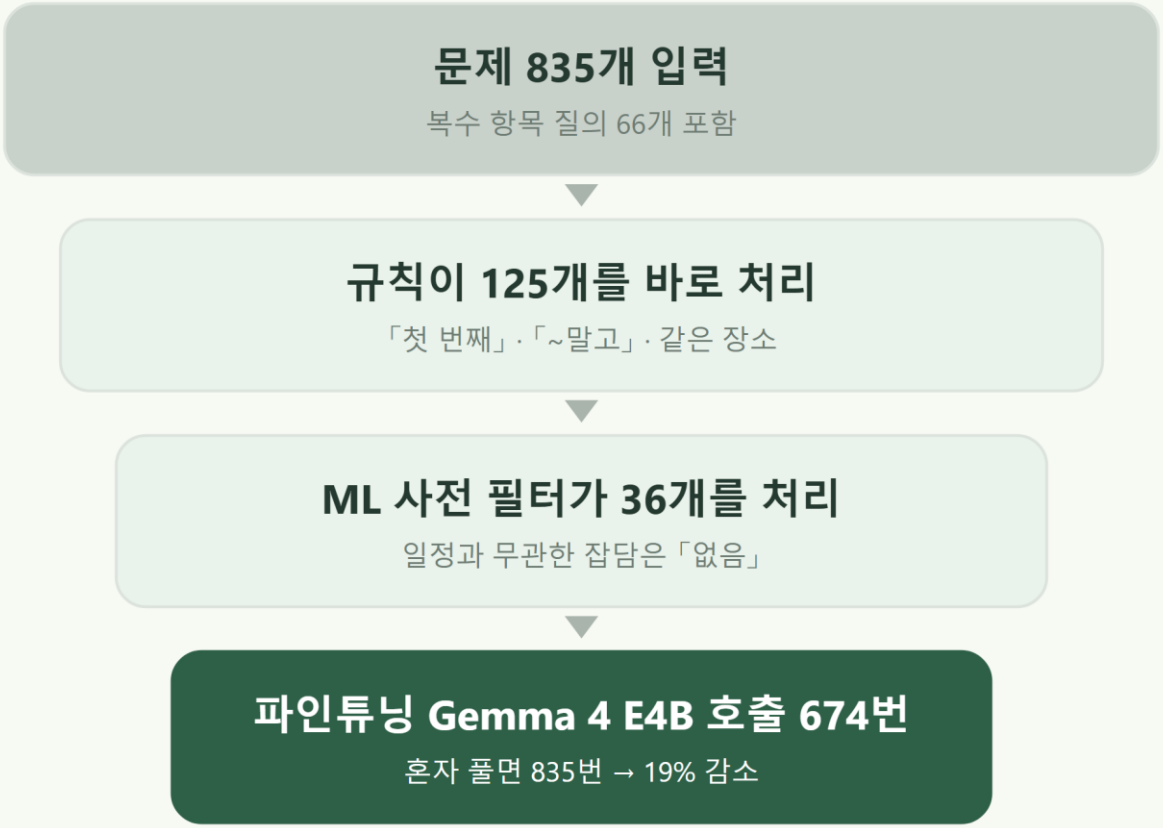
성능 · 응답 시간

우리 모델(무료 서버 · GPU) 97.3~97.5% · Luna 96.4% · Sol 98.8% (769문제, 상용은 공정 비교 아님)
응답: 무료 서버 이어지는 질문 7.7초 · GPU(파인튜닝 모델) 0.24초 · 새 일정 첫 질문 1.1초
→ Luna 경로가 클수록 쌈(하루 2만 건 월 약 15만 · 10만 건 약 32만원 차이) · API 몫 정확도 약 1%p 낮음

가정: 가장 몰리는 한 시간 = 하루 질문의 15%(콜센터 계획 기본값) · 그 시간 가동률 80% · 새 일정 첫 질문 20% · GPU = RunPod A4000 월 25.6만원 · 처리량 A4000 실측(파인튜닝 전 Gemma 4 E4B · 동시 8) · 30일. 장애 시 API 로 넘기는 장치는 cs 개발 세션에 맡김.

PIPELINE TEST

앞단을 두어도 점수는 구분되지 않았고 호출은 19% 줄었습니다



맞힌 문제 / 769

748

파인튜닝 Gemma 4 E4B 혼자

기준

745

앞에 규칙 + ML 사전 필터 추가

혼자와 구분 안 됨 (갈린 문제 3 : 6, p=0.51)

697

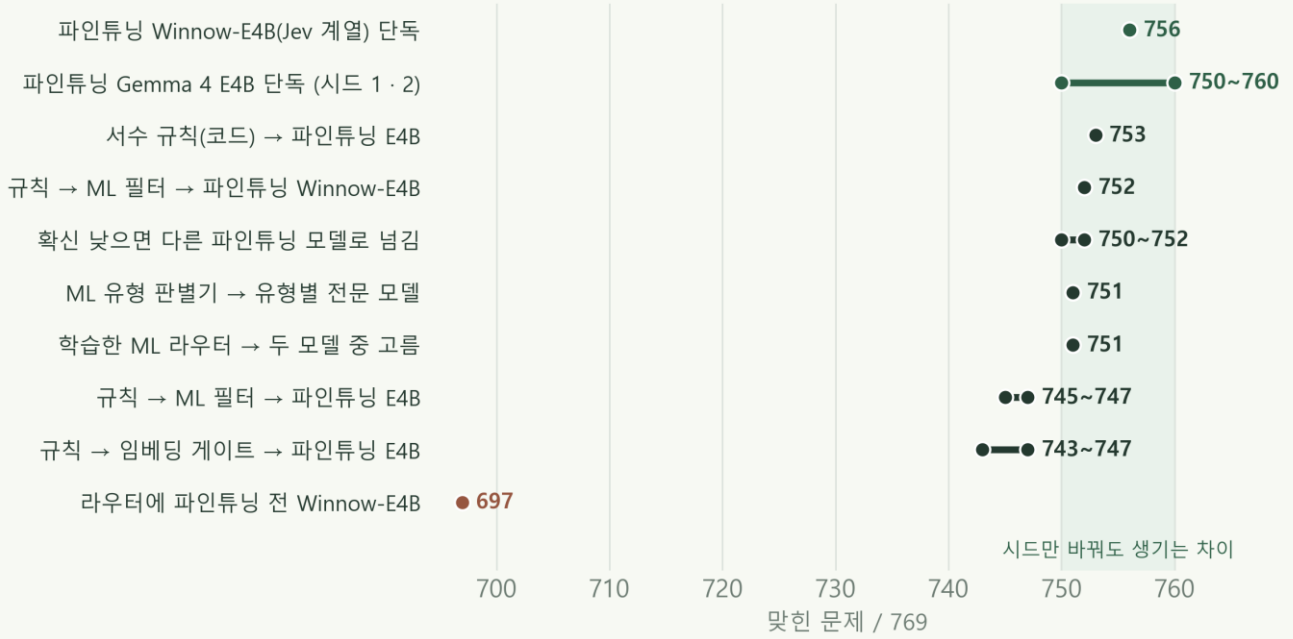
라우터에 Winnow-E4B 추가

Jev 계열 · 파인튜닝 전이라 공정 비교 아님.
사후 수정 버전 (미리 고정한 버전 472)

E2E 파이프라인 테스트: 단계를 실제로 이어 붙여 문제마다 처음부터 끝까지 호출(GPU 서버 C, 10-06). 같은 방법으로 파인튜닝한 두 모델을 섞은 구조는 747~752 로 혼자와 구분 안 됨.

COMBINATIONS

조합 여덟 가지 모두 단독 최고를 넘지 못했고, 이득은 호출 절감입니다



파트별로 맞는 모델을 붙인 지금 구성

고객 말 분류	학습한 인코더 · 의도 98 · 감정 95 · 긴급도 91 · 대상 95%
일정 항목 매칭	파인튜닝 Gemma 4 E4B · 서수 · 상대 위치는 규칙이 먼저
규정 검색	임베딩(bge-m3) · 제품 Recall@3 62.5% → 재순위 92.6%(제품 반영 전)
잡담 · 무관한 말	규칙 → ML 필터 · 호출 −19~23%

Jev 계열을 어디에 쓸 수 있나

인코더형(Laya · OpenDecider-nano)은 분류 46~81%로 못 씀. LLM형 Winnow-E4B 는 파인튜닝 전에도 의도 94.5 · 감정 91.0 · 대상 92.1% 지만 긴급도 63.5%. 파인튜닝하면 항목 매칭 756(Gemma 4 E4B 시드 2 의 760 과 구분 안 됨)

같은 769문제. 조합의 문턱 · 라우터는 한 세트를 빼고 고른 값. 두 파인튜닝 모델이 다른 답을 낸 문제가 12개뿐이라 고를 여지가 작았습니다. 분류 · 매칭 · 검색을 한 흐름으로 이은 시험은 아직 없습니다(맡김).

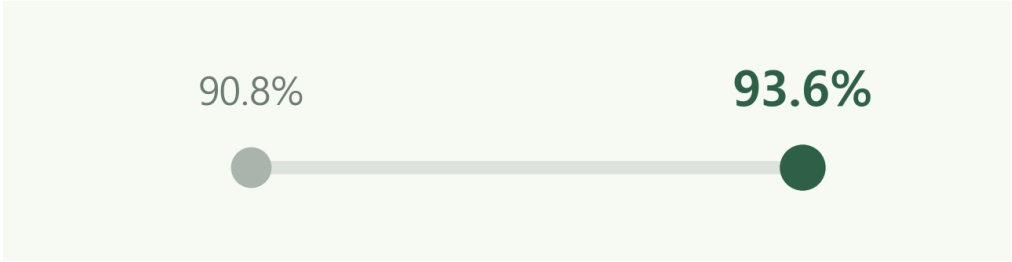
빈 답은 사라졌지만, 시드에 따라 85.6~93.7%로 흔들립니다

실제 채팅처럼 섞은 2,735문제

일정 질문	관광지 질문	일상 대화	구어체 문장
835	600	1,000	300

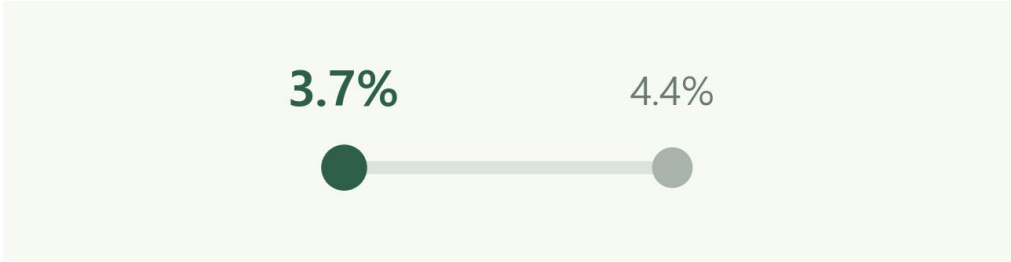
전체 정답률 · 생각 모드 켬 → 끔

시드 1 · 2,669문제 중 2,424 → 2,498 = 93.6% · 빈 답 81 → 0. 같은 방법으로 시드만 바꾼 3개는 93.7 · 85.6 · 90.9% (평균 90.1%)



무관한 말에 항목을 잘못 고름 · 앞단 없음 → 있음

시드 1 · 4.4% → 3.7%, 구분 안 됨(16 : 8, p=0.15). 시드 3개 단독은 4.3 · 16.0 · 7.3% — 갈리는 곳이 바로 여기



일정 질문만 있는 769문제는 시드 3개가 752 · 750 · 745 로 구분 안 됨 — 시드가 가르는 것은 무관한 말을 「없음」으로 거르는 정도. 앞단은 큰 모델 호출 −23%. 서비스에는 시드 1이 올라가 있음. 합성 시험.

고객 말 꼬리표 중 긴급도가 학습으로 가장 많이 올랐습니다

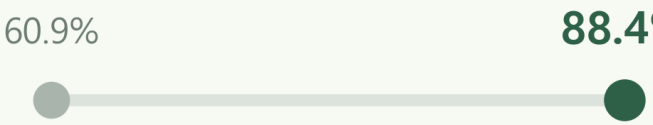
고객
식당 왔는데 우리 네 명 자리 없대요. 어떡하죠?

의도	대상	감정	긴급도
사건 신고	식당	부정	높음

꼬리표 네 개로 처리 순서와 담당을 정합니다.
「얼마나 급한가」는 문장에 잘 드러나지 않아
가장 어려웠습니다.

긴급도 정확도 · 400문장

학습 없이 지시문만 준 Gemma 4 E4B → 우리 문장 720개로 학습한 분류 모델



학습한 분류 모델의 나머지 꼬리표

의도	감정	대상
97.5%	93.8%	93.2%

CX 400 중 정답 칸이 있는 353문장(합성): 긴급도 312/353 대 215/353 · 갈린 문장 112 : 15, p=1.6e-19 · 차이 +27.5%p (+21.8~+33.1). 단 별도 평가셋 G96(96문장)에서는 네 꼬리표 모두 구분 안 됨 → 다른 자료로는 아직 일반화하지 못했습니다.

규정 검색은 지금 62.5%이고, 개선안 두 가지로 목표에 다가갔습니다

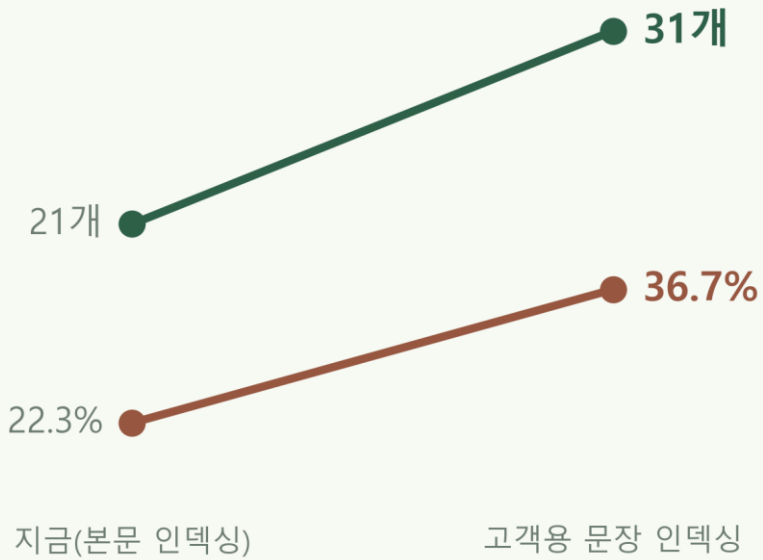
고객
창덕궁 임시 휴관이면 일정 어쩌죠?

찾아야 하는 규정 조각
「운영 중단과 통제」 문서 · 「임시 휴관과 정기 휴관을 나눈다」 절

지표 (블라인드 평가셋 B · 답 있는 48문제)	지금 → 개선 색인
Recall@3 정답 규정이 검색 상위 3개 안에 든 질문 비율	**62.5% → 72.9%**
Hit@2 고객 화면에 보이는 2줄 안에 정답이 든 비율	**50.0% → 70.8%**
정답 줄을 보인 질문 실제 답에 정답 규정 문장이 실린 질문 수	**21 → 31개**
선택적 위험 답한 것 중 틀린 비율 · 낮을수록 좋음	**51.2% → 27.9%**

개선안 2 · 재순위(후보 20개를 다시 줄 세움)
따로 둔 보류 세트 68문제에서 Recall@3 41 → 63개 = 92.6% (목표 90% 달성, 갈린 질문 23 : 1)

개선안 1 · 인덱싱 텍스트를 바꾸면 (직원용 본문 → 고객용 문장)
정답은 늘었지만 오응답도 늘었습니다



● 정답 규정을 보인 질문 (48문제 중)
● 예약 요청 같은 여행 말에 규정을 붙인 비율

그래서 분류 단계 뒤에서 다시 재고 제품 반영을 정합니다.

같은 질문 짝 비교: Recall@3 개선은 5 : 0, p=0.0625 로 경계(우연일 확률 약 6%) · 정답 줄은 10 : 0, p=0.002 로 유의. 오응답은 라벨 없는 여행 대화 300건, 의도 분류기를 거치지 않은 값. 규정 문장은 저장된 문장을 그대로 실어 인용 334/334.

사람이 35행을 직접 검수해 기계 검사를 확인하고 결함을 고쳤습니다

기계 검사와 사람 판정

18/19

같은 쪽으로 판정 = 94.7%
(75.4~99.1) · Cohen κ = 0.90

규정 답 24행 · 알림 번역 11행을
사람이 원문 · 답 · 근거를 직접 보고
맞다 / 중간 / 틀리다로 판정했습니다.
기계 의견은 판단 보조로만 썼습니다.

검수로 찾아 고친 것

고객 질문 「한파 특보인데 해돋이 일정 늦추나요?」

고치기 전 답 · 앞뒤가 모순

한파 규정을 실음: 「…몸을 녹일 실내 장소를
경로에 넣어 드려요. 해돋이는 옮기지 않고
준비물을 안내해 드려요」
끝줄: 「일정은 바꾸지 않았어요」

→

고친 뒤 · 제품 답 문구

머리말: 「해당하는 상황이 되면
이 기준으로 처리해요」
끝줄: 「지금 일정은 바꾸지 않았어요」
→ 규정은 「그런 상황이면」의 기준임이 드러남

규정 문장은 「그런 상황이 되면 해 드린다」는 일반 기준인데, 이미 해 준 것처럼 읽혀 끝줄과 부딪혔습니다. 정답 줄 검사(기계)로는 못 잡는 결함입니다.

10/24 규정 질문 답 「맞다」
틀린 줄만 보인 답 · 답 없는 질문에 답한 경우가 원인 → 규정 검색 개선 근거

9/10 알림 번역 「맞다」
보호 장치를 통과한 번역 8행은 모두 맞음

2026-10-06, 35행(틀리기 쉬운 쪽을 많이 뽑은 표본이라 서비스 전체 평균이 아님). 고친 곳: 규정 답 머리말 · 끝줄(itinerary_team.question_answer).

HOW WE MEASURE

지표와 통계 방법은 공개 벤치마크 · 논문 기준을 따랐습니다

무엇을	지표	근거 문헌	지금 값 (95% 구간)
규정 검색	Hit@2 · Recall@3 · MRR · nDCG@10	BEIR · MTEB	**Recall@3 62.5% (48.4~74.8)**
답할지 거절할지	거절 재현율 · 오거절 · 선택적 위험 · AURC	SQuAD 2.0 · Geifman·El-Yaniv	**선택적 위험 51.2% → 27.9% (개선 색인)**
근거 · 환각	문장 일치 회귀 시험 · 숫자 / 금액 단위 보존	Wang 2021 · Tang 2025	**인용 334/334 · 숫자 변조 0/115 (상한 3.2%)**
고객 말 분류	매크로 F1 · MCC · 네 축 동시 정답 · ECE	Guo 2017	**네 축 동시 CX 77.1% (71.9~81.6)**
일정 · 에이전트	오지목 · pass^k · 시드 변동	CLINC150 · τ-bench · Bouthillier 2021	**결정 단위 pass^3 91.3% (86.6~95.3)**
지연 · 오류	p50 · p95 · p99 · 오류 3분류	Dean·Barroso 2013 · Google SRE	**규정 답 p95 596ms · 오류 0/680**

통계 비율은 Wilson 구간 · 평균과 F1 은 부트스트랩 구간 · 두 방법 비교는 같은 질문 짝 McNemar 정확검정 · 0건은 0% 가 아니라 상한으로 적음

평가 설계서(2026-10-06): 논문 · 표준 약 70건 조사(본문까지 읽은 것 약 40건). 합성 질문 점수는 순위 비교에만 믿고 절댓값은 낙관으로 읽습니다(Rahmani 2024). LLM 판정기는 보조로만 씁니다(Zheng 2023).

SAME CONDITIONS

Sol 은 분류 · 결정에서 앞서고, 규정 재순위는 우리와 같습니다

지표 (같은 문제 · 같은 채점)	우리	Luna	Sol
고객 말 분류 · 네 꼬리표 동시 정답 G96 · 96문장 · Claude 초안 라벨	43.8%	55.2%	67.7%
결정 단위 · 3번 모두 맞음(pass^3) 172사례 × 3번	91.3%	92.4%	97.1%
규정 재순위 · Recall@3 보류 세트 68문제	92.6%	92.6%	86.8%
1건 비용	0원 · 우리 서버	0.25원	4.93원

Luna · Sol 은 Codex CLI 로 문제마다 불러 쟀습니다(API 직접 호출보다 느림 · 생각 설정 통제 불가라 공정 비교 아님). 규정 재순위는 우리와 2 : 2 로 구분 안 됨. 합성 문제 기준이며, 고객 말 분류는 합성 CX 400 에서만 우리 분류기가 앞섭니다.

COMMERCIAL READINESS

합성 시험으로 4개를 넘었고, 사람이 쓴 질문으로는 아직 확인 전입니다

지표	지금	상용화 기준	기준 출처	상태
응답 시간 p95	0.6~11.7초	**15초 이내**	양식 SLA	합성 넘음
일정 항목 매칭 (769)	97.3% (95.9~98.2)	**95% · 구간 하한 기준**	제안	합성 넘음
규정 인용 정확도	334/334	**100%**	팀 목표	합성 넘음
번역 숫자 · 금액 단위 변조	0/115 · 단위 대조 추가	**0건**	팀 목표	합성 넘음
규정 검색 Recall@3	제품 62.5% · 재순위 92.6%	**90% 이상**	양식	반영 남음
결정 단위 pass^3	91.3% (86.6~95.3)	**95% 이상**	계획서	미달
엉뚱한 대상 변경	1/172	**0건**	계획서	미달
계획 읽기 글자 오독	12/350 = 3.4%	**0건**	팀 목표	미달
무관한 말에 항목 오지목	시드별 4.3~16.0% · 제품 5.3%	**1% 이하**	제안	미달
긴급도 분류	CX 88.4% · 별도 셋 62.5%	**90% ·「높음」 재현율 95%**	제안	미달
사람 판정 규정 답「맞다」	41.7% (어려운 표본 24행)	**90% · 사람이 쓴 질문**	제안	미달

공통 조건 합성 문제가 아니라 사람이 쓴 실제 질문에서, 95% 구간의 아래 끝이 기준을 넘어야 상용화로 봅니다.

「제안」 기준은 틀렸을 때 고객이 입는 손해로 정한 Claude 제안이며 팀 결정이 필요합니다: 되돌리기 어려운 일(일정 변경 · 금액 · 지어낸 값)은 0건, 답의 정확도는 90~95%, 사람 판정은 90%.

OPEN ISSUES

남은 큰 문제는 무관한 말 오지목과 규정 질문 놓침입니다

이번에 해결

✓ 번역 금액 단위 대조

「35,000원」→「35,000円」같은 단위 바꿈을 거름 · x600 서버 반영

✓ 규정 답 앞뒤 모순 문구

사람 검수로 찾아 머리말 · 끝줄 문구를 고침

✓ 빈 답: 제품은 이미 막혀 있음

제품 호출은 생각 모드를 끄고 있음 · x600 서버에서 재현 확인 0/20 대 20/20

✓ 오응답을 실제 경로로 잼

규정 오응답 8/2,110 = 0.4% · 검증 단계를 넣으면 0.1%

남은 것

5.3%	**일정과 무관한 말에 일정 항목을 짚음** 실제 경로 · 일상 대화 · 구어체 69/1,300 · 그중 일정까지 바꾸려 한 것 18/1,300	RAG
26%	**규정 질문을 규정으로 못 알아봄** 「바꿔줘요?」같은 요청 말투 39/148 · 검증 단계를 넣으면 정밀도 80.0 → 87.6%	RAG · cs
2건	**엉뚱한 일정 변경 1/172 · 계획 읽기 글자 오독 12/350** 대상 확인 안전장치 · 두 받아쓰기 맞춰 보기를 다른 세션이 만드는 중	진행 중
켜짐	**파인튜닝 Gemma 4 E4B 서비스 연결 · x600 반영(10-07)** 첫 문장은 규칙, 모델은 뒤에서 읽음 · 웹 채팅 끝까지는 아직 확인 안 함 · 재순위 · 검증 단계는 반영 전	cs
일부	**실서버: 실제 사용자 흐름** 서버 응답 · 웹 경로 55개 · 재난 뒤 패널은 확인 · 로그인 · 여행 만들기는 시험 여행 허락 필요	결정 필요

실제 경로 = 고객 문장 → 결정 단위(gemma4:12b) → 규정 질문일 때만 규정 검색 → 문턱 0.55. 문장 2,340개 · 1회 · AI 합성과 공개 대화 자료. 규정만 따로 잰 22~37%는 결정 단위가 거르는 단계를 뺀 값이었습니다.

NEXT WEEK

다음 주에는 무관한 말 오지목과 규정 질문 놓침을 줄이고 제품에 반영합니다

지금 막힌 것	다음 주에 할 것
무관한 말에 일정 항목 5.3%	→ 잡담 · 범위 밖을 「없음」으로 넣어 다시 가르치기 · 일정 변경은 확인 질문 · RAG
규정 질문 놓침 26%	→ 요청 말투 규정 질문 예시 추가 · 검증 단계(정밀도 87.6%) 반영 · RAG · cs
모델로 거르기 아직 효과 없음	→ 교차 인코더 이어 학습 76.5% — 12B 재순위 92.6% 를 못 넘음 · 다른 방식 시험 · RAG
재순위 · 검증 단계 반영 전	→ 재순위 · 검증 단계를 제품에 넣고 웹 채팅 끝까지 확인 · cs
모델 순위 · 사용자 흐름 미정	→ 시드 3 · 4 · jevify · Plumb 학습 대기열(약 15시간) · 실제 사용자 흐름 확인 · RAG · cs

APPENDIX

이 발표의 시험 · 자료 · 구성 이름

팀이 붙인 이름만 모았습니다. 표준 기술 용어는 풀지 않았습니다.

mock 서버	서버 응답 모양만 흉내 내는 시험용 대역 서버
cs 프로젝트 서버	고객 요청을 처리하는 triPilot 앱(api · worker · web · db)
x600 서버	cs 프로젝트 서버가 올라가 있는 팀 기계
GPU 서버 A · B · C	모델 학습 · 시험용으로 빌린 원격 GPU 기계
항로 지킴이	문제가 생기면 서비스가 먼저 바꿔 두고 알릴지 고르는 스위치
Jev 계열 모델	선택지 중 하나를 고르는 결정 전용 공개 모델 묶음 (Winnow-E4B 등)
Jev API(유료)	같은 계열의 종량 과금 외부 결정 API
시험 세트 mix8~12	일정 항목 매칭 5묶음 835문제(AI 합성). mix8~11 Codex · mix12 Claude
769문제	835문제에서 복수 항목 질의 66문제를 뺀 주 지표 분모
복수 항목 질의	한 문장에 일정 항목 두 개를 묻는 질문
B · C 채점	B: 복수 항목 질의는 하나라도 맞으면 정답 · C: 낸 묶음이 정답 묶음과 같아야 정답
E2E 파이프라인 테스트	규칙 → ML 사전 필터 → 라우터 → 파인튜닝 Gemma 4 E4B 를 문제마다 실제로 이어 부른 시험
ML 사전 필터	일정과 무관한 잡담을 먼저 거르는 작은 분류 모델
혼합 트래픽 테스트	일정 835 + 관광지 600 + 일상 대화 1,000 + 구어체 300 = 2,735문제
블라인드 평가셋 B	규정 문장을 보지 않고 따로 쓴 규정 질문 160문제(답 있는 48)
CX 400	고객 문장 분류 평가셋 400문장(Codex 작성 · Claude 교차 라벨)
인덱싱 텍스트	규정을 찾을 때 질문과 비교하는 글
합성 문제	사람이 아니라 AI 모델(Codex · Claude)이 쓴 시험 문장